Booklet

Tus primeros pasos en la Ciencia de Datos

Yecely Díaz

Índice

Prólogo **2**

Introducción **3**

Aplicaciones de la Ciencia de Datos **6**

- Detección de fraudes 6
- Sistemas de recomendación 6

Conceptos básicos **8**

- Tipos de Datos 9
  - Datos estructurados 9
  - Datos no estructurados 10
  - Grafos 10
  - Multimedia 10
  - Streaming 11
- Data-Driven decision-making 11
- Minería de datos 13

El proceso de la Ciencia de Datos **15**

- Entendimiento del negocio y/o problema 15
- Recolección de los datos 16
- Preparación de los datos 16
  - 1. Eliminar registros 17
  - 2. Reemplazarlos con la media/mediana/moda 17
  - 3. Predecir valores faltantes. 18
  - 4. Asignar un valor único. 18
- Exploración 18
- Modelado 19
- Evaluación 20
- Implementación 20
- Presentación 21

Preguntas de entrevista **22**

Mi portafolio de datos **33**

Recursos gratuitos para tu preparación **36**
Libro Vivo de Ciencia de Datos (Español) 36
Machine Learning para todos (Español) 36
Aprende Machine Learning (Español) 37
Kaggle (Inglés) 37
KDNuggets (Inglés) 37
Dataquest (Inglés) 37
Towards Data Science (Inglés) 37

Libros **39**

Repositorios gratuitos de datos para tu portafolio **40**
Open data en Amazon 40
Kaggle 40
UCI Machine Learning Repository 41
Nasdaq Data Link 41
Data.gov 41

Recomendaciones finales **42**

Prólogo

Mi nombre es Yecely Díaz a.k.a. Yesi Days y te doy la bienvenida a este booklet.

Actualmente soy V.P. de Ingeniería y Datos en una fintech, trabajé como Científica de datos en una startup de entregas a domicilio y tengo experiencia como desarrolladora backend. Estudié un doctorado en Inteligencia Artificial dónde me especialicé en Minería de Datos y análisis de Redes Sociales, y también soy Google Developer Expert en Machine Learning. Este booklet fue escrito desde mi experiencia en el área y para ayudar a personas que se interesan en los datos, y así puedan tener un panorama inicial para su preparación.

La **Ciencia de Datos** es un campo que puede resultar intimidante para cualquiera, especialmente si eres nuevo en él. Sé lo que es empezar con poca o ninguna experiencia en la Ciencia de Datos y sentirse agobiada de la inmensidad de información que hay al respecto.

Por eso he escrito este booklet: son mis respuestas a todas las preguntas que me han hecho y he escuchado de otras personas que están por cambiar de rol o no saben por donde empezar. Quiero que tengas toda la información que necesitas para que puedas tomar decisiones informadas sobre tu travesía.

El objetivo es presentarte una serie de recomendaciones y recursos que he utilizado, compartirte técnicas, preguntas y respuestas de entrevista, y brindarte una guía inicial.

La intención es brindarte en cada capítulo escenarios realistas y consejos que se conviertan en una guía para ti, acompañándote en tu desarrollo y preparación.

Adicional a este booklet también diseñé una ruta de preparación y recopilé diferentes recursos gratuitos de la red y está disponible en el siguiente sitio.

Puedes hacerme llegar tus comentarios o sugerencias a mi correo personal silvercorp@gmail.com o enviándome un tweet a @silvercorp para compartirme que te ha parecido este booklet.

Muchas gracias por adquirir este booklet y principalmente por tu confianza, te deseo mucho éxito en tu preparación.

Introducción

La Ciencia de Datos, combina múltiples campos entre los que se incluye la estadística, inteligencia artificial (IA) y las ciencias de la computación. Se enfoca en utilizar métodos que permiten analizar datos de diversos tipos y extraer el conocimiento a partir de ellos.

El rol del Científico de Datos fue nombrado como *“el trabajo más sexi del siglo XXI”* convirtiéndose en uno de los campos en crecimiento y más solicitados por las empresas. Esto debido a los volúmenes de datos creados por medio de distintas fuentes de información, y que al analizarse generan grandes ventajas que pueden ser aplicadas al negocio en diferentes ramas.

Hay tres cosas principales que diferencian a los Científicos de Datos de otros tipos de profesionales: 1) tienen un fuerte conocimiento de la estadística, 2) tienen una comprensión del aprendizaje automático, y 3) saben cómo diseñar productos basados en datos.

Los datos recopilados describen distintos escenarios, generan beneficios económicos, conocimiento, crecimiento, etc. para las empresas de todo el mundo, y a partir de eso se deriva la necesidad de aprender a interpretarlos y obtener el mayor provecho de ellos.

Pensemos en la cantidad de información que se genera a través de los Sitios Web cuando navegamos, los registros realizados al usar el teléfono móvil, los patrones de sueño que capturan los relojes inteligentes, la cantidad de transacciones generadas por medio de las tarjetas bancarias. Esta inmensidad de datos se convierte en el insumo principal para conocer más a los usuarios, consumidores finales y el uso de los diferentes productos. Y es ahí donde entramos en acción como Científicos y Científicas de datos obteniendo el valor real de la información, por eso la relevancia del rol para la industria.

Por ejemplo, los datos pueden ayudar a detectar eventos anómalos como son transacciones fraudulentas en las tarjetas bancarias, predecir comportamientos observados, determinar correlaciones entre diversos eventos, y entender sistemas complejos a través de los datos.

Como Científicos de Datos podemos utilizar distintas técnicas para tener en cuenta los descubrimientos y predecir posibles resultados.

Los datos están en todas partes a través del insumo de diferentes fuentes de información, y es un buen momento para que aprendas a obtener ventaja de su análisis. Si estás en el proceso de iniciar tu carrera este booklet es para ti, más allá de explicarte código me enfoco en presentarte los conceptos y herramientas clave para que puedas prepararte.

Todo lo que aquí te presento lo puse en práctica durante mi cambio de rol, así que cada uno de los recursos y recomendaciones los apliqué también para mí.

Espero que sea de utilidad para ti y te ayude a prepararte para empezar en el mundo de la Ciencia de Datos.

Aplicaciones de la Ciencia de Datos

En el capítulo introductorio te presenté con brevedad la trascendencia de la Ciencia de Datos en la industria y algunas de sus aplicaciones. Su importancia ha logrado que las empresas se interesen en tomar decisiones más informadas y no intuitivas, que se encarguen de optimizar sus recursos y tener mejores rendimientos a través del análisis de los datos.

Las empresas se enfocan en encontrar nuevas maneras de acrecentar sus beneficios y disminuir sus deficiencias, por lo que la aplicación de la Ciencia de datos nos ayuda a aumentar los resultados de las empresas y apoyar a alcanzar sus objetivos.

Hay diferentes campos de relevancia en donde la Ciencia de datos ha logrado grandes mejoras y aplicaciones novedosas. Entre ellas se encuentran:

Detección de fraudes

Es un problema relevante y de interés principalmente para los bancos, y el objetivo es determinar la probabilidad de que una transacción sea falsa. Para ello, los primeros pasos son el reunir datos de cada operación, su fecha, lugar, monto, tipo de compra y un identificador del tarjetahabiente. Con los datos transaccionales podemos encontrar patrones de compra y etiquetar si cada transacción es válida o fraudulenta.

Si por ejemplo, el tarjetahabiente compra en su mayoría en ciertos tipos de tienda, con una regularidad entre los días 10 - 15 de cada mes y con un monto promedio de 500 USD, entonces si encontramos transacciones con un monto mayor a 2,000 USD en días fuera del rango y en una tienda de una categoría diferente su probabilidad de que sea fraudulenta se incrementa. Con este descubrimiento podemos enviar una notificación al tarjetahabiente para que confirme si se trata de él o una persona externa está intentando hacer una compra fraudulenta.

Sistemas de recomendación

Los sistemas de recomendación son un caso práctico en el cual nos vemos involucrados día a día y uno de los más conocidos en la aplicación de la ciencia de datos y el aprendizaje automático.

Uno de los más populares es Netflix y cómo es que nos recomienda series y películas que es posible nos pueden llegar a interesar o contenido que aún no hemos consumido y que considerando características similares a otros usuarios también pueden ser de interés para nosotros.

Amazon es otro caso muy conocido y que imagino que en más de una ocasión te has preguntado si te están “escuchando” y por eso saben que producto necesitas o deseas comprar al verlo entre tus recomendaciones. Sin embargo, la realidad es que tu historial de navegación, características de la cuenta, comparación con usuarios similares a ti, sus compras y más criterios le permiten al algoritmo presentarte productos que puedes llegar a necesitar. Y de igual manera cuando aparecen en tu sección de recomendaciones al no dar clic o ver su descripción, ese se convierte en un criterio adicional para confirmar que productos relacionados no te resultan interesantes. Con estos datos el algoritmo de recomendación se va ajustando o “reentrenando” para brindarte un mejor servicio e incrementar sus ventas.

Caso así hay diversos y su objetivo en su mayoría es mantenerte enganchado a la plataforma (Netflix, YouTube) e incrementar tus ventas o ticket promedio (Mercado Libre, Amazon).

Conclusión

Existen muchos casos prácticos donde el análisis de datos y en particular la aplicación de la Ciencia de Datos ayuda a mejorar la capacidad para abordar problemas de una manera analítica. Y es ahí cuando se vuelve importante el evaluar si los datos pueden mejorar el rendimiento, ayudan a la toma de decisiones y el alcanzar los objetivos con sustento en los datos.

Por lo tanto, es relevante que tengas buenas bases y conozcas los conceptos fundamentales que te ayuden a iniciar tu carrera en la Ciencia de Datos. En los siguientes capítulos te adentrarás aún más en las bases y en aquella información que me fue de utilidad para conocer más acerca de este rol y encontrar valor en las diferentes técnicas aplicadas al negocio.

Conceptos básicos

En este capítulo te presento algunos conceptos básicos con los cuales necesitas estar familiarizado.

Empecemos con el término ***Big Data*** el cual existe desde hace mucho tiempo, pero recientemente ha empezado a mencionarse más en el mundo de los datos. Esto se debe a que *Big Data* es cualquier colección de información que pueda almacenarse en grandes cantidades, como archivos de vídeo o publicaciones en redes sociales por mencionarte algo.

Cuando se trabaja con Big Data, no solo hay que preocuparse por el tamaño del conjunto de datos, sino que hay que pensar en lo que hace que los datos sean únicos y cómo eso puede ayudar a tomar decisiones, el cómo lo vamos a almacenar, de que manera validaremos su veracidad y el valor que brinda al negocio.

Para una gestión adecuada de Big Data es necesario conocer las llamadas 5 Vs que consisten en:

- **Volumen.** Cuando se habla de Big Data debemos pensar en la inmensa cantidad de información con la cual vamos a trabajar, estamos considerando tera bytes, peta bytes, etc., y como se incrementa dependiendo del caso de estudio.
- **Variedad.** En el análisis de datos te vas a contar con múltiples fuentes de información que pueden ser obtenidas de dispositivos móviles, redes sociales, transacciones bancarias, etc. La importancia de la recopilación de información varía dependiendo de donde vienen los datos que tan diversos son y cómo vamos a abordar su análisis.
- **Velocidad.** Además de trabajar con los datos, las compañías necesitan que la información se gestione con prontitud o lo más cercano a lo inmediato. Puede dar una ventaja competitiva si se procesan los datos en tiempo real, obteniendo en el momento justo para tomar decisiones estratégicas del negocio.
- **Veracidad.** Conforme trabajamos con datos notamos la importancia de la calidad en la información, y es necesario analizar su procedencia, si son datos limpios o si debemos hacer una investigación adicional de la veracidad de la fuente de datos.

Recordemos que nuestro análisis y toma de decisiones se basa en la información recopilada, por lo que debemos tener la seguridad de que es adecuado el conjunto de datos con el que se va a trabajar.

- **Valor.** Por último, el convertir conjuntos de datos recopilados en datos relevantes para el negocio y su toma de decisiones; cada una de estas características tiene sus propios retos y técnicas para ser resueltos. Se pueden enfocar en diferentes aspectos como es la captura de los datos, almacenamiento, limpieza de la información, búsqueda, transferencia, creación de conocimiento, visualización y procesamiento por mencionar algunos.

Cada una de estas características tiene sus retos propios y técnicas para ser resueltos, y pueden enfocarse en diferentes aspectos como es la captura de los datos, almacenamiento, limpieza de la información, búsqueda, transferencia, creación de conocimiento, visualización y procesamiento por mencionar algunos.

Durante el análisis de la información te encontrarás con diferentes tipos de datos que puedes adquirir de diversas maneras, por lo que es necesario que los conozcas a detalle.

Entre las categorías principales se encuentran los datos estructurados, no estructurados, grafos, multimedia (audio, video, imágenes) y de streaming. Por supuesto, esta clasificación puede variar; sin embargo, son aquellos con los que he trabajado.

Tipos de Datos

Datos estructurados

Los datos estructurados son aquellos que tienen un modelo de datos y que se puede extraer información de ellos de un modo muy simple. Se encuentran de manera ordenada lo que facilita su análisis.

Suelen ser almacenados en tablas dentro de bases de datos o archivos de Excel de manera que se puedan gestionar y consultar, por lo que tener un formato es una parte clave de los datos estructurados.

Datos no estructurados

Los datos no estructurados son aquellos que no tienen como tal un modelo de datos específico o rígido como si lo tienen los datos estructurados. Un ejemplo de esto es la información recopilada en redes sociales, como puede ser Twitter. Aunque los tweets pueden tener datos con estructura o “repetitivos” como es el nickname, tweet y fecha de publicación, también existen muchos datos adicionales como es si los tweets tienen integrados hashtags, archivos multimedia, menciones, retweets, etc.

Por lo que la recomendación sería guardarlo en un archivo sin estructura fija como puede ser un formato JSON o bases de datos NoSQL.

Grafos

Los datos basados en grafos son una estructura matemática para modelar las relaciones entre los diferentes objetos o nodos. Estas estructuras utilizan nodos, aristas y propiedades que representan y almacenan los grafos.

Es posible que no los encuentres de manera recurrente como pueden ser los estructurados y no estructurados, pero es importante que los conozcas por su relevancia. Es una forma de presentar las redes sociales y una estructura más natural, y entre sus ventajas se encuentra que puedes calcular métricas como pueden ser la influencia de una persona y el camino más corto que conecta a más personas.

Un ejemplo de esta estructura es lo que encuentras en LinkedIn y como se presenta la relación entre tu red de contactos, otro ejemplo es la preferencia de cada usuario por el tipo de contenido en la plataforma de Netflix. Una tecnología que se puede usar para esto es Neo4J por su estructura, métodos implementados y la posibilidad de escalar.

Multimedia

Otros tipos de datos con los que puedes hacer ciencia de datos son los de tipo multimedia, que incluyen imágenes, audio y video. El analizar estos datos plantean desafíos diferentes comparados con los de texto plano. Entre las tareas que suelen involucrarse son el reconocimiento de objetos, selección de fragmentos en el audio, reconocimiento de patrones, aprender e interpretar secciones de imágenes, videos o audio utilizando aprendizaje profundo.

Aunque pueden ser menos recurrentes las solicitudes en las cuales vas a colaborar, hay áreas muy particulares donde son datos necesarios para solucionar problemas particulares como es videovigilancia, reconocimientos de rostros, en el área médica, videojuegos, entre otros.

Streaming

Por último, los datos tipo streaming o también conocidos como datos en flujo, y son aquellos que se reciben a mayor velocidad que los anteriores y se producen cuando sucede un evento o una acción. Pueden ser cualquiera de los tipos de datos anteriores y aquí la diferencia radica en cómo se obtienen y llegan los datos que pueden ser por lote o en tiempo real. Un ejemplo de tipo streaming son las redes sociales, datos de eventos deportivos, lo que puedes recibir de una aplicación de entregas a domicilio o mercado de valores. Es aquello que tiene una actualización recurrente, por lo que también su complejidad es diferente debido a que deberás incluir técnicas de análisis de datos que involucren grandes cantidades de información.

Data-Driven decision-making

Una siguiente etapa una vez que sabes con qué tipos de datos vas a trabajar es conocer lo que se denomina ***Data-Driven decision-making (DDD)*** o en español se conoce como la toma de decisiones basadas en datos. Es la acción de definir nuestras decisiones a través del análisis de los datos y el no solo enfocarnos en la intuición o lo que nuestros sesgos pueden indicarnos.

Los científicos de datos utilizan entonces su conocimiento de los datos para hacer recomendaciones basadas en los resultados de su análisis.

Hay tres componentes principales en DDD:

El primer componente es ***comprender*** cómo se pueden usar los datos para tomar decisiones. Esto incluye saber qué preguntas necesitas responder, de cuántas maneras diferentes puedes responder a esas preguntas y en qué momento del proceso es apropiado tomar decisiones.

El segundo componente es comprender a su ***público y sus necesidades***. Es decir, entender quiénes son, qué les preocupa y qué les gusta o disgusta de su

producto/servicio. Esto le ayudará a determinar si hay margen de mejora en su producto/servicio y, si lo hay, cuál es la mejor manera de abordarlo.

El tercer componente es la ***comprensión de las restricciones***: ¿qué limitaciones existen en relación con los datos disponibles? Por ejemplo si está limitado a una ciudad, personas, si es un servicio que solo acepta tarjetas de crédito, etc. por mencionar algunos.

Te pondré un ejemplo, pensemos en una tienda en línea de ropa que debe seleccionar los anuncios a presentar considerando únicamente lo que el sector y la experiencia de sus vendedores le indican, sin embargo, esto no nos permite tener una medición adecuada ni hacer caso a lo que nuestros mismos consumidores finales o nuevos visitantes nos están indicando. El objetivo de aplicar *DDD* es demostrar estadísticamente cuál es el interés real de nuestros compradores y posibles compradores con características e intereses similares. Para ello podemos integrar herramientas como Google Analytics y Tag manager para conocer que tipo de ropa se vende más, en qué secciones navegan más los usuarios, que artículos tienen mayor número de interacciones, etc. Esto lo podemos asociar al interés general de nuestros consumidores y adaptar los anuncios, ofertas y secciones que debemos usar para presentar nuestra publicidad. *DDD* se relaciona a incrementar nuestro rendimiento, utilización adecuada de la información y la relación con estos elementos.

Es importante señalar que la toma de decisiones basada en datos no consiste únicamente en recopilar datos y analizarlos, sino en pensar qué tipo de preguntas queremos hacer, cómo queremos que se respondan nuestras preguntas y cómo queremos que se presenten esas respuestas para que todo el mundo pueda entenderlas.

Como Científicos de Datos debemos utilizar a nuestro favor esta información e identificarlas en dos tipos: aquellos patrones que descubrimos en los datos y aquellos patrones repetitivos. En el primer caso, podemos llegar a encontrar interacciones que no hubieran sido encontradas a simple vista como, el interés de compra de artículos nuevos cuando tienen envíos gratis a diferencia del interés de compra cuando tienen un 20% de descuento. En este caso, nuestra estrategia de venta puede inclinarse a dar envíos gratis en lugar de descuentos.

Y en segundo caso, se encuentran los patrones repetitivos como es el incremento de ventas en días de quincena o cuando se acercan fechas especiales como 14 de febrero o días de las madres, en ese caso, nuestra estrategia de venta la podemos preparar con anticipación y presentar anuncios enfocados a ello.

Esa es la diferencia de tomar decisiones por intuición o analizar los datos al alcance o de fuentes externas para ejecutar decisiones con un valor para la empresa.

Minería de datos

La **minería de datos**, es otro concepto que debes conocer, y se describe como el conjunto de técnicas y tecnologías que permiten extraer información a partir de la exploración de grandes bases de datos. Esto puede realizarse de manera automática o semiautomática, siendo el objetivo encontrar patrones repetitivos que expliquen el comportamiento de los datos explorados.

Te presento algunos ejemplos al usar la minería de datos para responder a preguntas como:

- ¿Cuál es la mejor manera de mejorar mi producto/servicio?
- ¿Qué necesita realmente el cliente de este producto/servicio?
- ¿Debo invertir en esta empresa?
- ¿Es el canal de comunicación adecuado?
- ¿En dónde estoy perdiendo la retención?

El análisis de datos por medio de la minería de datos aporta diversas ventajas para las empresas y entre ellas se encuentran:

- La posibilidad de analizar grandes cantidades de datos
- El descubrimiento de información que no está a simple vista
- Los resultados obtenidos son sencillos de interpretar dado el uso de técnicas.
- Aplicar el conocimiento adquirido al negocio y toma de decisiones
- Ahorrar costes en la detección de áreas de mejora y apertura de oportunidades de negocio.

Con lo que has leído, tal vez hayas encontrado amplia similitud con el concepto de Ciencia de datos, sin embargo, existen diferencias importantes entre ellas.

La ciencia de datos es una disciplina que involucra distintas áreas de conocimiento y la minería de datos se refiere al uso de técnicas para extraer información útil de grandes conjuntos de datos en bruto.

Aunque ambas tienen en común obtener el mayor beneficio del procesamiento y análisis de los datos, sus propósitos y resultados van a variar.

Cada una utiliza los datos de forma distinta y aunque coinciden en algunas etapas de análisis la ciencia de datos va un paso más adelante al integrar herramientas de Inteligencia Artificial, y tiene como objetivo general el analizar el conjunto de datos con el fin de descubrir conocimiento útil para la toma de decisiones.

Conclusión

Ahora que ya conoces los conceptos básicos o que más vas a estar empleando, te comparto con más detalle en el siguiente capítulo cuál es el proceso general que se aplica cuando hacemos Ciencia de Datos y me enfocaré a detallar cada punto para que conozcas la relevancia y el objetivo de cada etapa.

El proceso de la Ciencia de Datos

El rol del Científico de Datos es muy solicitado y el campo está creciendo rápidamente. A medida que aumenta la necesidad de automatizar los procesos empresariales los datos se convierten en una herramienta importante para ayudarles a lograr los objetivos planteados.

Utilizar Ciencia de datos implica llevar un proceso claro con una estructura que nos permita resolver un problema y logre una coherencia en los resultados de los objetivos planteados. Este proceso suele constar de seis pasos que son:

- Entendimiento del negocio o problema
- Recolección de los datos
- Preparación de los datos
- Exploración
- Modelado
- Evaluación
- Implementación
- Presentación

A continuación explico a detalle cada punto.

Entendimiento del negocio y/o problema

Es fundamental tener claridad del problema que vas a resolver y comprensión del negocio y los objetivos. Para ello, la solución será un proceso iterativo de descubrimiento, entendimiento y enfoque de los resultados.

En esta etapa debes tener una comunicación directa con otras áreas como puede ser negocio, marketing, el cliente final y con ellos consultar tus dudas o revisar la documentación que te proporcionen.

Entre algunas de las preguntas que debes tener en cuenta son: ¿qué necesitamos resolver?, ¿cómo planeamos hacerlo?, ¿tenemos dependencias de otras áreas?, ¿cuál es el objetivo?.

Al discutir esto tendremos una base inicial y conforme avancemos nos daremos cuenta con mayor detalle del escenario a resolver.

Recolección de los datos

La segunda etapa es la recolección u obtención de los datos, y es de donde debemos recopilar los datos que necesitamos, donde podemos encontrarlos o si vamos a requerir hacer una búsqueda adicional de información.

El objetivo es resolver el problema, y los datos son la base fundamental para hacerlo y aquello que nos ayudará a proponer una solución. Es por eso que es importante comprender con lo que contamos, las limitaciones y analizar si es necesario adquirir datos adicionales de fuentes externas.

Los datos que nos proporciona el área correspondiente es bastante probable que no esté completa, que debas crear atributos calculados, o que muchos de ellos no sean útiles. Esta etapa es exhaustiva y el análisis te puede llevar la mayor cantidad de esfuerzo. La recomendación es que te tomes tu tiempo y tengas la seguridad de que estás comprendiendo cada uno de los datos y valides con qué propósito puedes usarlos, siempre recordando que no importa el modelo o su complejidad, si tú no cuentas con la información adecuada tus resultados no serán los idóneos.

Una frase que aprendí al iniciar mi preparación es: “Datos basura te dan resultados basura”, es por eso la importancia de tomarte tu tiempo en esta y la siguiente etapa debido a su alta relevancia.

Preparación de los datos

En la etapa anterior nos enfocamos a comprender aún más el problema, tener conocimiento de nuestro insumo principal y la resolución de dudas a partir de ellos. Sin embargo, sabemos que no es un proceso perfecto, es apenas la segunda etapa y está propenso a errores, datos faltantes, requerimientos de normalización, validez de los datos, etc. Es por eso que debemos mejorar la calidad de los datos y preparar un correcto uso para las fases posteriores. Esta etapa es desde mi punto de vista la más

costosa y que te va a llevar más tiempo, es normal que la mayor parte del proceso la efectúes aquí.

Parte de esta etapa se enfoca en la limpieza de los datos eliminando valores falsos, posibles incoherencias en la información y el enriquecimiento de la fuente de datos. Además, el cálculo de atributos que se integran y la transformación de los datos que garanticen el formato adecuado para los usos posteriores.

Uno de los grandes desafíos al cual te enfrentarás en esta etapa son los valores nulos o vacíos que pueden ser representados como NULL, NA o como un campo empty. Para este caso particular te comparto 4 técnicas para tratar con ellos.

1. *Eliminar registros*

Aunque es una técnica conocida, es la que menos trato de aplicar como primera solución, excepto que sean muy pocos registros que tienen valores nulos. En este método el objetivo es eliminar filas concretas que cuenten con valores nulos o columnas en caso de que su pérdida de información sea mayor al 70%.

Sus ventajas radican cuando trabajan con grandes conjuntos de datos donde la eliminación de pocos registros (ej. 1%) pueden no causar ruido, sesgos o perdidas mayores.

Su desventaja principal es la pérdida de información y datos, no es recomendable si vas a eliminar más del 30%-35% de tus datos o si tienes pocos registros con los cuales trabajar.

En mi caso, es la última solución que considero.

2. *Reemplazarlos con la media/mediana/moda*

Esta técnica puedes aplicarla a datos de tipo numéricos como son: la calificación, el precio de un billete, la edad de una persona. Si encuentras valores nulos podemos calcular la media, mediana o moda de todos los datos de ese atributo y el resultado sustituirlo por el valor faltante. Esta es una solución estadística que aunque podemos tener fuga de datos la aproximación de estos valores evita perderlos como se tienen con la técnica anterior.

Entre sus ventajas se encuentran, un mejor resultado cuando el tamaño de los datos es pequeño y evitar la pérdida de datos si es que aplicamos la técnica de eliminación de

filas y columnas. Y sus desventajas son el sesgo que se incluye en la información y que a mayor cantidad de valores faltantes los resultados no son óptimos.

3. *Predecir valores faltantes.*

Esta técnica requiere de utilizar algoritmos de aprendizaje automático, como puede ser una regresión lineal para sustituir los valores nulos y reemplazando con otros datos disponibles. Es posible experimentar con más algoritmos para obtener el resultado. Al hacerlo así existe una alta probabilidad de incluir un sesgo en tu conjunto de datos.

4. *Asignar un valor único.*

Esta técnica se efectúa agregando el valor que más se repite en los valores faltantes para no afectar a la variable. En este punto debemos considerar que tanto puede incluir más ruido que ventajas, por ejemplo, si el valor más común aparece el 80% de las veces, entonces vamos a sesgar nuestro conjunto de datos.

Como puedes notar existen diferentes métodos que nos ayudan a preparar datos en particular cuando hablamos de valores nulos, es una fase que lleva tiempo y debemos encontrar el equilibrio entre hacerlo simple y tener una transformación que evite pérdidas masivas de información. Conforme avanzamos y trabajamos con más problemas, tenemos mayor conciencia del impacto de cada decisión, y en ocasiones ese tiempo conlleva a planear por medio de prueba y error, explorar con mucho detalle y nos lleva a tener descubrimientos más adecuados para cada problema.

No hay una receta o pasos únicos, eso depende de cada solución que debamos plantear, y es importante que tengas la paciencia para explorar, intentar y replantearte tus ideas. Es relevante que al finalizar tu preparación de datos finalices con un conjunto de información limpio, ordenado, normalizado y listo para trabajar.

Un aspecto final que debes tener en cuenta, es que es posible que conforme avances a las siguientes etapas notes que debes volver a revisar el proceso de preparación de datos. Dar un paso atrás y replantear tu solución.

Exploración

El objetivo de la exploración de los datos es el de profundizar y tener mejor conocimiento de lo que estamos analizando. En esta fase utilizamos estadística

descriptiva, modelos sencillos y técnicas visuales que a primera vista nos ayuden a entender con mayor detalle que podemos encontrar en los datos.

Esta etapa la denominamos como EDA por sus siglas en inglés Exploratory Data Analysis (Análisis Exploratorio de Datos).

EDA tiene ventajas, como:

- Tener una mejor comprensión de las variables de nuestra información, mediante la extracción de promedios, medidas de dispersión, correlación, etc.
- Descubrir valores atípicos, valores faltantes, errores en la información, etc.
- Identificar patrones y comportamientos en los datos.
- Identificar variables que pueden ser utilizadas para predecir y realizar pronósticos.

A partir de aquí puedes crear gráficas que te apoyen visualmente a la comprensión de la información como el uso de Box plot, histogramas, gráficos de dispersión, etc.

Modelado

En la etapa de modelado es el momento en que se aplican técnicas de los campos del aprendizaje automático, estadística y conocimiento del negocio. Usamos por primera vez la versión del conjunto de datos que preparamos con anterioridad, por eso su relevancia al dedicar tiempo para tener datos de calidad. A partir de aquí debes enfocarte en desarrollar modelos descriptivos o predictivos dependiendo del problema a resolver. Tendrás que explorar, comparar, ajustar los parámetros de ser necesario y todo esto dependerá de que solución necesitamos y el modelo que mejor se adapte para lograrlo.

El proceso de modelado es normalmente iterativo lo que deriva en algunos ajustes en la preparación de los datos, selección de las variables y algunas especificaciones propias del modelo.

Es posible y probable que intentemos utilizar múltiples modelos con sus parámetros respectivos, para así hacer una comparación de resultados, alinearlos a los objetivos y el problema a resolver.

Evaluación

Una vez que hemos seleccionado y desarrollado el modelo en una primera versión y antes de que hagamos una implementación final, el objetivo de esta etapa es evaluar al modelo para de este modo garantizar que aborda y resuelve el problema de una manera adecuada.

Para ello, debemos evaluarlo con diferentes métricas, diagnósticos y comparación de resultados, puedes utilizar tablas y gráficas que nos permitan interpretar la eficacia y calidad del mismo.

Las métricas más utilizadas para la evaluación de modelos son:

- Matriz de confusión.
- Exactitud.
- Precisión.
- Exhaustividad
- Puntuación F1
- ROC
- Pérdida logarítmica
- Índice Jaccard
- Coeficiente de Gini

Si vas a trabajar con Python no es necesario que programes cada métrica, si usas la librería de scikit-learn puedes invocarlas, enviar los parámetros y tener el resultado.

Implementación

Cuando el modelo, las métricas son satisfactorias y cumple con el objetivo a resolver es momento de continuar con la implementación en un entorno de pruebas y después productivo. Esta fase es probable que como Científico de datos no necesitemos hacerlo y tengamos apoyo de un rol denominado Ingeniero de Machine Learning. Por lo general tenemos ese apoyo y somos parte del equipo de seguimiento e implementación. Menciono esta fase como opcional y depende mucho de cómo esté integrado el equipo de trabajo al que perteneces.

Presentación

Por último, se encuentra la fase de presentación de los resultados al equipo que puede ser negocio, marketing, growth o con quienes nos encontramos colaborando.

Los resultados pueden mostrarse de diferentes formas, desde una presentación con gráficas y descubrimientos, un dashboard con los resultados relevantes, informes, la implementación en producción y su solución, etc.

También debemos tener claridad de que es lo que está esperando nuestro cliente o el área con quienes colaboramos, el objetivo es resolver sus dudas y cumplir con los objetivos establecidos desde un inicio.Existe también la posibilidad de que una vez presentando los resultados necesitemos hacer un paso iterativo más, ajustar y presentar nuevos resultados.

Es por eso la importancia de asegurarnos desde la primera fase de comprender los objetivos, las necesidades del negocio y confirmar que es lo que esperan recibir.

La metodología presentada ilustra una manera iterativa de lo que implica realizar un proceso de Ciencia de datos para la resolución de problemas. Es normal que debas regresar a alguna etapa para llevar a cabo ajustes conforme vamos teniendo descubrimientos en los datos y en la mejora del modelo, además de los resultados obtenidos.

De este modo, el modelo y la presentación de resultados proporcionan un valor importante a la empresa y para su toma de decisiones.

Preguntas de entrevista

En este capítulo te presentaré un listado de tips y preguntas recurrentes en los procesos de entrevistas para un rol de Ciencia de Datos. El objetivo es brindarte información que sea útil para ti y tu preparación y tengas una idea de que suelen preguntar y debes abordar los procesos.

Por supuesto, el tipo de preguntas va a cambiar así como lo que esperan de ti dependiendo del nivel, la experiencia y/o empresa. Me estaré enfocando principalmente en roles juniors e intermedios.

Un proceso de entrevista típico para el rol de Ciencia de datos incluye diferentes etapas, a menudo cubren conceptos teóricos donde el objetivo es determinar si el candidato conoce los fundamentos en los procesos de ciencia de datos y también del aprendizaje automático.

Considera también que debes tener conocimiento del negocio por lo que te recomiendo que si te estás postulando a una empresa realices un análisis y búsqueda exhaustiva de a que se dedican, cuál es su misión y visión, y de ser posible tengas conocimiento del producto. Esta información en su mayoría la podrás encontrar en su sitio Web, LinkedIn de la empresa y de ser posible te recomiendo enviarle un mensaje a un ex-colaborador para que te cuente su experiencia.

No olvides considerar las preguntas enfocadas a las habilidades blandas, a lo que tú puedes aportar como posible colaborador y tu experiencia previa. En caso de que no tengas experiencia previa debes destacar tus habilidades blandas y lo que has hecho por tu cuenta.

A continuación te comparto un listado de posibles preguntas que te harán y sus respuestas.

¿Cómo se aplica la estadística en la Ciencia de Datos?

Cuando trabajamos con datos debemos pensar también en probabilidades siendo esta una parte importante de la estadística. De la misma manera cuando trabajamos con modelos como la regresión logística, árboles de decisión, KMeans, etc. tienen una base

en la estadística, de la misma manera las predicciones son inferencias basadas en las distribuciones de los datos.

Es decir, como Científicos de Datos debemos sustentar nuestros resultados y comprobar los descubrimientos obtenidos, por lo que el uso de modelos probabilísticos y predicciones son un ejemplo claro de la aplicación de la estadística en nuestro campo.

¿Qué es el aprendizaje automático supervisado?

El aprendizaje automático de tipo supervisado es cuando nuestros algoritmos se entrenan utilizando datos previamente etiquetados y a partir de ello se predice el resultado basándose en esos datos.

Un ejemplo de esto puede ser una colección de datos de tarjetahabientes en donde se tiene la etiqueta fraude y los atributos etiquetados pueden ser la transacción, el monto, la fecha y hora de la transacción, el lugar donde se realizó, etc. El algoritmo aprende con este conjunto de atributos y cada ejemplo tendrá la etiqueta de “Fraude” o “No Fraude”. Cuando tengamos un nuevo ejemplo sin etiquetar el algoritmo con su aprendizaje previo nos va a indicar si existe o no un posible fraude.

¿Qué es el aprendizaje automático no supervisado?

Por el contrario, el aprendizaje no supervisado se utiliza para identificar nuevos patrones a partir de datos no etiquetados; estos algoritmos aprenden a partir de relaciones, patrones, características similares, etc. El término “no supervisado” se refiere a que el algoritmo que no está siendo guiado a través de los datos como es el caso del algoritmo de tipo supervisado.

Por ejemplo, si tuviéramos un conjunto de datos de compradores en una tienda en línea y deseamos encontrar diferentes segmentos de clientes sin una etiqueta previa podemos usar un algoritmo de tipo no supervisado para encontrar similitudes en las compras de los diferentes clientes y agruparlos, de manera que el equipo de marketing diseñe una estrategia de venta dependiendo del segmento que le haya asignado el algoritmo.

¿Cuál es la diferencia entre muestra de los datos y población?

La muestra es un subconjunto de la población y se representa con la letra n minúscula.

La población es la colección de todos los elementos para nuestro estudio y suele representarse con la letra N mayúscula.

¿Qué es el sobreajuste?

El sobreajuste también conocido en inglés como *overfitting* es cuando un modelo se ha entrenado de manera que intentamos “hacer encajar” los datos de entrada a expensas de la generalización de nuevos datos. Es decir, el modelo ajustará su aprendizaje a casos particulares a través de los datos de entrada y será incapaz de reconocer nuevos datos, por lo que el modelo será incapaz de distinguir nuevas entradas si sale de los rangos previamente establecidos.

Un ejemplo de sobreajuste es si deseamos aprender a distinguir tacos de un conjunto de imágenes de diferentes tipos de comida, si las imágenes solo tienen tacos al pastor y el modelo aprende únicamente con esas imágenes entonces cuando presentemos una nueva imagen de un taco de carnitas y le preguntemos al modelo si es un taco nos dirá que no lo es debido a que no conoce nada más que un taco al pastor. Hemos sobreajustado tanto el modelo que no ha aprendido características suficientes.

¿Cómo validas tus modelos?

Una manera de validar nuestros modelos consiste en dividir nuestro conjunto de datos en tres partes que son: datos de entrenamiento, validación y pruebas. Por lo general, se toma entre el 70% y 80% del conjunto de datos como entrenamiento y el porcentaje restante como datos de prueba. Las muestras deben tomarse de manera aleatoria y no de manera secuencial para lograr mayor generalización del modelo.

Es importante dividir nuestros datos en entrenamiento, validación y prueba para proporcionar una evaluación no sesgada y mejorar la generalización del modelo. De esta manera se evita que únicamente aprenda con cierta parte del conjunto de datos.

Otra estrategia para validar nuestros modelos es mediante validación cruzada o también conocida como cross-validation.

¿Qué es la validación cruzada?

La validación cruzada o en inglés conocida como cross-validation es una técnica muy conocida y empleada para probar la eficacia de un modelo. La validación cruzada k-fold consiste en dividir nuestro conjunto de datos en un número *K*.

El método dividirá el conjunto de datos en K secciones o partes, y se utilizará la primera parte en la primera iteración para probar el modelo y las partes restantes para entrenar al modelo.

Cuando tenemos conjuntos de datos limitados es un buen procedimiento para realizar un remuestreo y así evaluar el modelo. Posteriormente, la segunda parte se usará para probar y las partes restantes para el proceso de entrenamiento. Es un proceso iterativo utilizando cada parte (K) hasta que el conjunto de pruebas utiliza todas las partes (Ks).

El proceso iterativo tiene como fin reducir el sesgo que tendría la selección de un solo conjunto de validación.

¿Qué modelos de clasificación conoces?

Los modelos de clasificación supervisada se utilizan frecuentemente por lo que hay diversos y son ampliamente utilizados en la industria. Entre los más aplicados se encuentran regresión logística, árboles de decisión, redes bayesianas y máquinas de soporte vectorial; adicionalmente existen variaciones de cada uno de ellos.

¿Qué es la regresión logística? ¿La has aplicado alguna vez?

La regresión logística es un algoritmo de clasificación binaria y se utiliza cuando se desea predecir la presencia o ausencia de una característica. Se debe usar cuando su variable Y solo puede tomar dos valores, y se dice que la variable es “binaria” o “dicotómica”.

Una variable se le conoce como dicotómica cuando puede tomar solamente dos valores posibles.

Un ejemplo de uso es cuando deseamos determinar si un correo electrónico es “Spam” o “No Spam”, cuando una cuenta de Twitter es “Real” o “Bot”, etc.

¿Cómo evaluas tus modelos de clasificación?

El objetivo de la validación de los modelos es conocer la validez de los resultados, evitar posibles sesgos, poder identificar posibles riesgos y tener la posibilidad de ajustar los parámetros.

Las diferentes métricas para poder evaluar un modelo se encuentran: exactitud (accurracy), precisión, recall, F1 score, pérdida de entropía cruzada, coeficiente de similitud de Jaccard.

¿Cuál es la diferencia entre la exactitud (accuracy) y la presión?

Las métricas de precisión y exactitud (accuracy) suelen confundirse y creer que son iguales aunque existen diferencias entre ellas.

La precisión la podemos definir como la medición de la calidad del modelo, y su fórmula es:

$$precisión = \frac{TP}{TP + FP}$$

en donde TP es “True Positive” y FP es “False positive”

Por otro lado, la exactitud (accurracy) mide el porcentaje de casos en que el modelo ha acertado, siendo su fórmula

$$exactitud = \frac{TP + TN + FP + FN}{TP + TN}$$

en donde TN es “True Negative” y FN “False Negative”

Me puedes explicar para qué sirve una matriz de confusión. ¿Qué indican las celdas?

La matriz de confusión nos permite visualizar el desempeño de un algoritmo y muestra cuántos TP (True Positive - Verdaderos Positivos), TN (True Negative - Verdaderos Negativos), FP (False positive - Falsos positivos) y FN (False Negative - Falsos Negativos) ha logrado el modelo. Cada columna de la matriz representa el número de predicciones de cada clase y cada fila representa las instancias de la clase real.

Es importante mencionar que se utiliza para algoritmos de tipo supervisado debido a que necesitamos un etiquetado previo para realizar la comparación y la validación de lo encontrado por el modelo.

Las celdas representan lo siguiente:

- Verdadero positivo (TP). Es cuando el valor real es positivo y la prueba también predijo que es positivo.
- Verdadero negativo (TN). El valor real es negativo y la prueba también lo etiquetó como negativo.
- Falso negativo (FN). La etiqueta real es positiva y la prueba le asignó un resultado negativo.
- Falso positivo (FP). La etiqueta es negativa y la prueba lo etiquetó como positivo.

Visualmente se representan así:

		Predicción	
		Positivos	**Negativos**
Observación	**Positivos**	Verdaderos Positivos (VP)	Falsos Negativos (FN)
	Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

¿Qué es la curva ROC y como se utiliza?

La curva ROC (de sus siglas en inglés Receiver operating characteristic) es una métrica de evaluación que nos ayuda a verificar el rendimiento de un modelo de clasificación. Es una buena opción para conocer cuál es el rendimiento del modelo de una manera visual.

Cuando entrenamos un modelo binario el objetivo es saber si la instancia es positiva o negativa, pensemos en un ejemplo para que sea más claro.

Considera que tienes transacciones bancarias y de las cuales pueden ser fraudulentas o legítimas, ese será tu valor binario. Posteriormente, hemos seleccionado un modelo que

sea capaz de clasificar las transacciones y obtendremos cuál es la probabilidad de que la transacción sea fraudulenta o legítima.

Si la probabilidad obtenida por el modelo está por arriba del 0.5 entonces asignamos la etiqueta “legítima” y si está por debajo de ese valor entonces la etiqueta “fraudulenta”.

Es posible que probemos con diferentes umbrales y validar si hemos mejorado la presión del modelo.

Es ahí donde la medida de ROC indica el ratio de positivos reales y el ratio de positivos falsos con distintos umbrales de clasificación.

¿Qué es la regularización y que técnicas conoces?

La regularización es un método que se utiliza para reducir o restringir el exceso de sobreajuste en los modelos de aprendizaje. Ayuda a los modelos a regularizar mejor y hacerlos más robustos ante el ruido en los datos y los valores atípicos.

Tres técnicas principales de regularización son: Ridge Regression (L2 Norm), Lasso (L1 Norm) y Dropout

¿Qué es la selección de características?

La selección de características (Feature Selection) es un método utilizado para seleccionar las características más importantes y/o relevantes de un conjunto de datos para que el modelo sea entrenado. Su objetivo es mejorar el rendimiento de la predicción, tener predictores más rápidos, mejorar la comprensión del proceso del análisis de los datos y eliminar las características irrelevantes que hacen que el modelo tenga un rendimiento inferior o el análisis sea poco valioso.

Algunos de los métodos más populares son: filtros, wrapper, embebidos e híbridos.

¿Qué son los árboles de decisión?

Los árboles de decisión es un algoritmo de tipo supervisado y extremadamente popular principalmente para problemas de clasificación. También proporcionan la base para otro tipo de métodos como son bagging, random forest y gradient boosting.

Como su nombre lo indica tienen una estructura de árbol en la que cada nodo interno (hoja) denota una prueba sobre un atributo y cada una de las ramas representan el

resultado de la prueba, y por último cada nodo terminal contiene un valor para la variable objetivo.

La base del algoritmo es dividir a los datos en dos o más conjuntos homogéneos basándose en los atributos independientes más significativos y tener grupos lo más distintos entre sí.

¿Cuáles son las ventajas de usar árboles de decisión?

Algunas de las ventajas de usar árboles de decisión son:

- Pueden usarse para problemas de clasificación y regresión
- Pueden utilizarse para predecir valores continuos y discretos.
- Por su estructura son más sencillos de interpretar los resultados
- Son rápidos y eficientes en comparación con otros algoritmos de clasificación

¿Has aplicado árboles de decisión? Dame un ejemplo.

Un ejemplo popular y que se aplica en la industria es validar si una persona es sujeto de crédito o no a partir de un conjunto de características como pueden ser su ticket promedio, número de compras por mes, tipo de tarjeta, promedio de ingresos, entre otros.

A partir del conjunto de atributos se generan las “rutas” o ramas para que la etiqueta final sea el ofrecer o no un crédito. Al ser un algoritmo de tipo supervisado debemos entrenar previamente a nuestro algoritmo con los atributos y etiquetas asignadas.

¿Qué es un random forest?

El método de aprendizaje Random Forest pertenece a una clase más amplia de los algoritmos de aprendizaje automático debido a que es la combinación de varios modelos para resolver un problema de predicción. Los Random forest es una extensión del bagging que además de construir árboles basados en múltiples muestras de sus datos de entrenamiento, también restringe las características que pueden utilizarse para construir los árboles teniendo como resultado árboles diferentes. Esto a su vez puede mejorar el rendimiento del modelo.

¿Qué son los métodos de boosting y bagging?

Los métodos de aprendizaje que combinan algoritmos simples usando boosting y bagging son ampliamente populares y se denominan como algoritmos ensamblados.

Se conocen como ensamblados debido a que son la unión de algoritmos más “sencillos” que al unirse forman un algoritmo más robusto y potente, y las técnicas más usadas para ensamblarlos son boosting y bagging.

Los métodos de bagging son aquellos donde los algoritmos simples se aplican en paralelo, y su objetivo es el aprovechar la independencia que existe entre los algoritmos “simples” debido a que el error se puede reducir al promediar las salidas de los modelos simples. Por lo que una manera de reducir la varianza de las estimaciones es promediando estimaciones de distintos modelos o algoritmos.

En el caso de boosting, los modelos simples se utilizan de manera secuencial. Es decir, se usan un modelo y posteriormente se aplica el siguiente modelo. El objetivo de los métodos secuenciales es el aprovechar de la independencia de los modelos más simples.

Las predicciones de cada modelo simple se combinan por medio de una votación (clasificación) o por una suma ponderada (regresión) para tener una predicción final.

La diferencia entre ellos es que en boosting los algoritmos no se entrenan de manera independiente y se ponderan según los errores de los modelos anteriores.

¿Qué es una red neuronal?

Una red neuronal o también llamado aprendizaje profundo (en inglés deep learning) es un método de la Inteligencia Artificial que le enseña a las computadoras a procesar datos de una forma inspirada en como lo hace el cerebro humano. Utiliza los nodos o neuronas interconectadas mediante una estructura de capas similar al cerebro humano, y crea un sistema adaptable donde las computadoras pueden aprender de sus errores y tener una mejora continua.

Estas redes neuronales artificiales intentan resolver problemas con una complejidad alta como son el reconocimiento de rostros u objetos, clasificación de objetos, detección de sonidos, realización de resúmenes de documentos, entre otros.

La importancia de las redes neuronales artificiales radica en como las computadoras pueden tomar decisiones inteligentes con una asistencia humana limitada, y como su

aprendizaje puede modelar relaciones entre datos de entradas y salidas que no son lineales y altamente complejos.

¿Qué es la función de activación?

La función de activación en una red neuronal devuelve una salida que se genera por la neurona dada una entrada o conjunto de entradas. Cada una de las capas que conforman la red tienen una función de activación que permite reconstruir o predecir. En ocasiones la función de activación también se conoce como función de transferencia.

Muchas funciones de activación son no lineales y pueden denominarse “no linealidad” en la capa o en el diseño de la red.

La elección de la función de activación tiene un alto impacto en el rendimiento de la red neuronal y se pueden utilizar diferentes funciones de activación en distintas partes del modelo.

Definición de ReLU

ReLU por su significado en inglés rectified linear activation function (unidad lineal rectificada) es un tipo de función de activación que se representa matemáticamente como y = max(0, x).

Es la función de activación más utilizada en redes neuronales especialmente en las conocidas como convolucionales.

ReLU es lineal para todos los valores positivos y cero para todos los valores negativos, es decir:

- El modelo puede tardar menos en entrenarse o ejecutarse.
- Converge más rápido
- La linealidad significa que la pendiente no se satura cuando X se hace más grande.
- Una red compuesta únicamente por funciones de activación lineal es muy fácil de entrenar, pero no puede aprender funciones de mapeo complejas.

¿Qué es backpropagation?

El algoritmo de backpropagation o retropropagación es probablemente el más conocido y fundamental para una red neuronal. El algoritmo se utiliza para entrenar de manera eficaz una red neuronal mediante un método llamado “chain rule” o regla de la cadena.

De manera simple de explicar, después de cada pase hacia adelante de la red, backpropagation se encarga de realizar un pase hacia atrás mientras se ajustan los parámetros del modelo, es decir, sus pesos y sesgos.

En otras palabras, backpropagation pretende minimizar la función de coste ajustando los pesos y sesgos de la red, y el nivel de ajuste viene determinado por los gradientes de la función de coste con respecto a esos parámetros.

Conclusión

Aunque existen muchos conceptos y diversidad de preguntas en una entrevista de Ciencia de datos, las preguntas anteriores te pueden dar una idea inicial de lo que debes saber y como puedes empezar a prepararte.

Por supuesto existen muchas preguntas con un enfoque teórico y aunque no debes saberlo todo te recomiendo que al menos los conceptos anteriores los tengas en tu mente y de ser posible revises más información acerca de ellos.

Mi portafolio de datos

Un portafolio es un medio con el cual puedes mostrar tú conocimiento y habilidades en la Ciencia de datos y puedes integrar en él proyectos reales en los que has trabajado o aquellos que has desarrollado para practicar o adquirir conocimiento. La ventaja de un portafolio comparado a un curriculum (CV) es que puedes plasmar de una manera concreta lo que sabes hacer y para un reclutador o líder técnico es más sencillo evaluar tu potencial a diferencia de un CV que requiere preguntas adicionales para validar lo que sabes o hiciste en su momento.

Una recomendación es que al construir tu portafolio de Ciencia de datos puedas contar una historia, es decir, plasmar el objetivo del análisis, como construiste el proyecto, porque decidiste usar tal modelo y los resultados objetivos. De esta forma quién lea tu análisis podrá tener una idea más concreta de como abordaste el problema, cuál fue tu solución y que lograste con ello.

Una manera de presentar tu portafolio es a través de un blog y presentar tus análisis, y para extenderte un poco más y presentar tu código te recomiendo tener una cuenta en Github o Gitlab con tu código bien documentado y una sección de README donde presentes una breve descripción del proyecto, la explicación de cómo configurarlo y algunas especificaciones adicionales a tus datos y proyecto.

Debemos recordar que uno de los objetivos de un Científico o Científica de datos es el poder añadir valor al negocio a partir de la comprensión y análisis del problema, un ejemplo de esto es:

Análisis exploratorio de un conjunto de datos de Facebook

Un ejercicio que puedes hacer es obtener el siguiente conjunto de datos de Facebook e identificar a los usuarios que más interactúan y a partir de ahí crear una campaña para incrementar el número de “likes” o interacciones, además de tener descubrimientos (insights) como los siguientes:

- El grupo más representativo y que más interactúa con las publicaciones se encuentran entre los 21 a 30 años y quienes menos interactúan son mayores a 60 años.

- Hay más hombres que mujeres sin embargo, las mujeres son quienes más interactúan con el contenido.
- El 71% de los usuarios navegan desde un dispositivo móvil

Considerando algunos de los descubrimientos anteriores se pueden lleva a cabo estrategias de posicionamiento e incremento de interacciones si enfocamos los mensajes a los grupos más grandes, ajustamos el tipo de contenido para las personas de entre 21 a 30 años y que las imágenes que publiquemos tengan un texto que sea fácil de leer desde dispositivos móviles principalmente.

Lo anterior son solo algunos ejemplos de como podemos crear soluciones que brinden un valor al negocio.

Para presentar soluciones así en tu portafolio puedes hacerlo mediante un post en un blog describiendo paso a paso que hiciste, que técnicas usaste para limpiar los datos, que descubriste y como esto puede impactar al negocio.

La manera de presentar tus soluciones asegúrate de demostrar las siguientes habilidades:

- Comprensión de los datos
- Capacidad de comunicación
- Habilidades técnicas
- Conocimiento del negocio
- Iniciativa para aprender

Un punto adicional que te recomiendo considerar es pensar en que no únicamente personas con conocimiento técnico van a leer tu portafolio, recordemos que en Ciencia de Datos podemos trabajar con diferentes áreas como negocio, marketing, growth, etc., y de ahí la importancia de poder expresarnos no únicamente con términos técnicos.

A continuación te comparto el listado de portafolios de otros científicos de datos para que los puedas tener de referencia:

- Claudia Ten Hoope
- Sajal
- H. Jansma
- Luis Lauriano
- Naledi Hollbruegge

- James Le
- Yan Holtz

Ahora es tu turno de empezar y mostrar tus avances ya sea en un blog o en tu repositorio en Github, lo importante es iniciar y avanzar poco a poco, esta es una de tus cartas de presentación que puedes usar para demostrar tus habilidades y lo que puedes aportar al negocio.

Recursos gratuitos para tu preparación

Desde mi punto de vista nunca ha habido un mejor momento para iniciar una carrera en datos como lo es actualmente, y se estima que el número de vacantes seguirá creciendo en un 30% principalmente en Estados Unidos, y por otro lado, en general el área tecnológica requiere cada vez más roles diversos que ayuden a resolver problemas y crear productos rentables.

Y a pesar de que durante el 2022 ha habido muchos despidos y diversas startups han terminado sus operaciones también ha habido un incremento en inversiones para nuevas ideas y por lo tanto, contrataciones con mejores salarios y prestaciones muy atractivas.

Por lo anterior te invito a que continúes tu preparación en el área de los datos y así poder enfrentarte a las diferentes pruebas técnicas y entrevistas. A tu disposición tienes diferentes recursos gratuitos en Internet que puedes utilizar de manera que tengas la información suficiente además de esta guía que preparé para ti.

A continuación te comparto un listado de recursos en español e inglés para que complementes tu aprendizaje.

Libro Vivo de Ciencia de Datos (Español)

Es uno de mis recursos favoritos debido a su claridad, ejemplos prácticos y los diferentes temas que abarcan. Su autor Pablo Casas es el fundador de la escuela en línea **Escuela de Datos Vivos**, y con su amplia experiencia plasmó en su libro en línea los conceptos básicos y fundamentales para iniciar en la Ciencia de Datos.

Machine Learning para todos (Español)

Es un blog donde no encontrarás únicamente temas de Ciencia de Datos, también temas relacionados como son el aprendizaje automático y aprendizaje profundo. Tiene contenido extenso, bien explicado y con un nivel de detalle que te va a ayudar a comprender mejor los diferentes conceptos.

Aprende Machine Learning (Español)

Uno de mis blogs favoritos por su amplio contenido, explicaciones detalladas, sencillas y gráficas que acompañan la explicación. Su autor publica constantemente y también ha integrado recientemente publicaciones que incluyen código, lo que complementa el aprendizaje.

Kaggle (Inglés)

Es imprescindible que tengas una cuenta en este sitio. Te ayudará a contar con conjuntos de datos para que practiques, encuentras código explicado y detallado, comunidad activa, concursos con premios, bolsa de trabajo, cursos gratuitos, etc. Si estás en busca de guías de aprendizaje y muchos datos con los cuáles aprender no debes buscar más y recurrir directamente a **Kaggle**.

KDNuggets (Inglés)

Para mi KDNuggets es el blog definitivo y más completo para aprender temas de datos y aprendizaje automático. Tiene una comunidad amplia, repositorios de datos para uso público, código fuente, explicación de conceptos básicos y avanzados, publicaciones diarias, boletín y bolsa de trabajo. Es el mejor sitio que vas a encontrar y con temas diversos para que lo utilices como una fuente más para tu preparación. Uno de los recursos que te recomiendo es su banco de preguntas útiles para tus entrevistas de trabajo, que abarcan áreas como SQL, análisis de datos, aprendizaje automático, Python, implementación en producción, etc.

Dataquest (Inglés)

En este sitio encontrarás lecturas, ejercicios y rutas de aprendizaje. Aunque no es totalmente gratuito la mayoría de su contenido es de libre acceso como es el caso de Ciencia de Datos en Python. Es otro recurso que no debes perderte por tu contenido actualizado, completo y su comunidad amplia con la que puedes hacer networking.

Towards Data Science (Inglés)

Es una de las publicaciones más amplias y completas dentro de Medium que se actualizan diariamente con temas correspondientes a diferentes roles de datos como es el caso de análisis de datos, ingeniería de datos, aprendizaje automático, automatizaciones, implementaciones, herramientas en la nube y mucho más. El único

hecho de dedicar tiempo a la lectura de estas publicaciones te brindará una visión más completa de los datos y todo lo que existe alrededor de ellos. Es sin duda otro de mis recursos favoritos.

Libros

En la presente sección te voy a recomendar un listado de libros que en lo personal me sirvió durante mi preparación, no es necesario que los adquieras todo ni tampoco que los leas en su totalidad. En mi caso me enfoqué solo en algunas secciones y conforme iba avanzando revisaba capítulos muy particulares y los combinaba con ejercicios prácticos de Kaggle y de KDnuggets.

- Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python
- Python Data Science Handbook: Essential Tools for Working with Data
- Data Science from Scratch: First Principles with Python
- Storytelling with Data: A Data Visualization Guide for Business Professionals
- Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow: Concepts, Tools, and Techniques to Build Intelligent Systems

En caso de que desees aprender Python te recomiendo los siguientes libros:

- Python Crash Course, 2nd Edition: A Hands-On, Project-Based Introduction to Programming
- Learning Python: Powerful Object-Oriented Programming

Te reitero que no es necesario que adquieras todos los libros o que los leas de principio a fin, esto que te comparto es solo un recurso adicional por si así lo deseas.

Repositorios gratuitos de datos para tu portafolio

En la sección **Mi portafolio de datos** te presenté como crearlo y sus ventajas al tener uno cuando estás buscando trabajo o te encuentras en entrevistas. Para ello es necesario contar con diferentes fuentes de datos y que sean variadas para así diversificar tus conocimientos o en todo caso que tu experiencia se enfoque en algún sector de tu interés.

En esta sección te presento un listado de repositorios gratuitos de datos que puedes usar para tus análisis, storytelling y portafolio.

Open data en Amazon

Amazon a través de su plataforma Amazon Web services comparte grandes conjuntos de datos que puedes descargar y trabajar con ellos ya sea desde tu máquina local o si tienes cuenta en Amazon puedes utilizar su nube. Lo único que necesitas es crear una cuenta en AWS y explorarlos sin necesidad de que pagues por ellos, en este caso te recomiendo descargarlos y trabajar de manera local.

Entre los repositorios más populares se encuentran los relacionados a temas de salud en particular Cáncer, COVID-19, NASA e imágenes de la tierra.

Tienes mucho por donde explorar y divertirte con ellos.

Kaggle

Kaggle como lo mencioné tiene una amplia variedad de conjuntos de datos públicos que puedes utilizar para tu preparación, exploración, análisis, portafolio, etc. La ventaja que veo de Kaggle es que sus datos son diversos e interesantes, que pueden ir desde temas muy técnicos o científicos como datos de cáncer de mama hasta datos de ocio y divertidos como Pokémon y Dragon Ball.

Para descargar los datos únicamente debes registrarte en Kaggle y sin costo alguno tienes acceso a su plataforma así como a todos sus conjuntos de datos.

Puedes usarlos en su plataforma creando “notebooks” (espacios de trabajo) o también desde tu máquina local.

En mi punto de vista, es el sitio ideal para encontrar conjuntos de datos interesantes, útiles y desafiantes.

UCI Machine Learning Repository

Sin duda alguna el repositorio de datos más grande, completo y antiguo en la red. Los datos son compartidos y documentados por usuarios por lo que encontrarás diferentes niveles de información y especificidad en cada conjunto de datos. Una de las ventajas de trabajar con datos de este repositorio es que encontrarás diferentes niveles de dificultad, algunos datos están en su mayoría limpios, estandarizados y bien documentados, y en otros casos tendrás que convertir el tipo de datos, tendrás datos nulos y poca información implicando un reto aún mayor.

Puedes descargarlos directamente a tu computadora sin necesidad de contar con un registro y empezar cuanto antes a analizar y aplicar tus conocimientos de Ciencia de datos.

Nasdaq Data Link

Es un repositorio de datos financieros y económicos, puedes encontrar conjuntos de datos gratuitos y también de paga. La mayoría de sus datos son muy completos e ideales para construir modelos e indicadores económicos, estimaciones y predicciones. Es ideal para crear un portafolio enfocado a fintechs.

Data.gov

Data.gov permite descargar datos de múltiples agencias del gobierno de Estados Unidos, y actualmente cuenta con un total de 318,999 conjuntos de datos de diversos tipos, los cuales pueden abarcar desde presupuestos, nivel educativo, salud, energía, etc.

Un punto posiblemente negativo es que algunos de estos conjuntos de datos necesitan investigación adicional para comprender con mayor detalle de que se trata y te das una idea concreta de cómo puedes usarlo para tus análisis.

Estos son algunos de los repositorios gratuitos más populares y que utilizo cuando deseo aprender un nuevo algoritmo o necesito probar alguna idea nueva. Como lo mencioné también son útiles en caso de que desees crear tu portafolio o si estás aprendiendo análisis de datos y aprendizaje automático.

Recomendaciones finales

Felicitaciones por llegar hasta este punto del booklet y por decidir iniciar tu carrera en la Ciencia de Datos, espero que te parezca de utilidad lo que he plasmado y compartido basado en mi experiencia.

Para finalizar voy a compartirte mis recomendaciones finales y los puntos más importantes que te presenté a lo largo de los capítulos.

Define tu objetivo.

Como en cualquier otra área es relevante que definas un objetivo y la razón por la cual quieres aprender ciencia de datos, esto te va a ayudar a no perder la motivación y el enfoque. Los objetivos son diversos y cada uno define por que desea hacerlo, ya sea por un cambio de carrera, interés en la industria, mejorar tu salario, trabajar en la empresa de tus sueños, etc.; sea lo que sea mantente enfocado en ese objetivo.

Para mí fue un cambio de carrera y aplicar lo que había aprendido en la teoría, eso me ayudó a no desistir y continuar con mi preparación.

No busques el camino fácil

Es normal que al inicio te parezca abrumador todo lo que está alrededor de la Ciencia de Datos y creas que jamás vas a concluir de aprender, sin embargo, el buscar el camino más corto o saltarte los fundamentos solo hará que eventualmente debas regresar y volver a intentarlo, no puedes correr si antes no aprendes a caminar.

Inténtalo paso a paso y no desees aprenderlo todo en un fin de semana, puedes iniciar con el análisis de datos, después los algoritmos más básicos de aprendizaje automático, hacer tu primera publicación para tu portafolio y compartirlo en redes sociales. De esta forma tendrás pequeños éxitos y sin abrumarte por la cantidad de contenido que puedes encontrar en la red.

Comunicación

Una habilidad fundamental en la Ciencia de datos es la comunicación debido a que constantemente debemos presentar los resultados de los análisis a todo tipo de público

y de ahí radica la importancia de ser concretos, pensar no únicamente en conceptos técnicos y presentar accionables.

Para que mejore tu comunicación es importante que conozcas perfectamente de que se tratan los datos que usaste en tu análisis y cuál es el objetivo de realizar el análisis, si eso lo tienes claro podrás explicar mejor y de una manera concreta. También será de ayuda que previamente organices bien tus ideas y prepares un storytelling o presentación con los descubrimientos más valiosos y te olvides de agregar aquello que no aporta al resultado.

Por último, si colaboras con otras áreas y hay conceptos que aún no comprendes pregúntalos o investígalos, debes tener conocimiento del dominio para que sepas de lo que estás hablando y si los resultados son aplicables o no.

Mejora tus habilidades técnicas

Te recomiendo que enfoques tus esfuerzos en mejorar paulatinamente tus habilidades técnicas en las diferentes áreas como son la estadística, programación e inteligencia artificial. En cuanto a la estadística inicia con las bases y los conceptos necesarios para tener un análisis, en programación selecciona un lenguaje como Python (recomendado) o R y realiza ejercicios para que tengas mayor conocimiento en el lenguaje y en el caso de Inteligencia Artificial puedes iniciar conociendo los algoritmos más populares.

Es un proceso que en mi experiencia tendrás mejores resultados si los pones en práctica y vas incrementando el nivel de complejidad, de esta forma te encontrarás con nuevos casos prácticos, problemas a resolver y tendrás un portafolio más completo.

No te olvides de las bases de datos.

Aunque en ocasiones tendrás acceso a conjuntos de datos listos para su análisis en otras ocasiones tú tendrás que hacer la consulta y exportación de la información, es por eso que es necesario que tengas conocimiento de bases de datos y en particular de SQL. Esto te brindará ventajas en la manipulación de la información y en definir desde el inicio la estructura, normalización y etiquetas de tu conjunto de datos. Te recomiendo que hagas ejercicios de consultas en la plataforma Hacker Rank.

Perseverancia y constancia

Por último, ser constante y perseverante son elementos clave en tu preparación. Es normal que te sientas abrumado, que haya momentos en que deseas detenerte o sientas que no avanzas sin embargo, es ahí cuando debes tener muy claro cual es tu objetivo y lo que deseas lograr.

Conclusión

La ciencia de los datos es un campo apasionante y es increíblemente importante para que las empresas se aseguren de que están utilizando sus datos correctamente y obtienen un valor a través de ellos.

El objetivo de escribir este booklet es ayudarte a empezar con los fundamentos de la Ciencia de Datos y conozcas un poco más acerca del tipo de preguntas que te pueden llegar a hacer en una entrevista y los recursos que he utilizado para mi aprendizaje, y los cuales espero que también sean útiles para ti.

Por último, me gustaría decir que tu decisión ha sido acertada al iniciar en un campo relevante en los negocios y en la industria en general, y a pesar de la inmensidad de información que hay allá afuera no te agobies y lleves paso firme en tu aprendizaje, espero que este booklet te ayude a encontrar tu camino en el mundo de la Ciencia de Datos.

¡Mucho éxito!