

Conoce tus herramientas para ciencia de datos

Flavio Cesar Sandoval

Data Enginner and Data Analyst



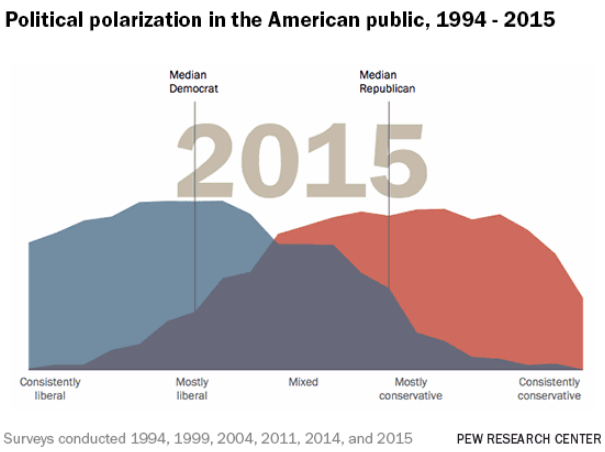
Redes Sociales

- LinkedIn: flaviocesarsandoval
- Twitter: DSandovalFlavio
- GitHub: DSandovalFlavio
- Email: flaviocesarsandoval@gmail.com



Lo que más me gusta

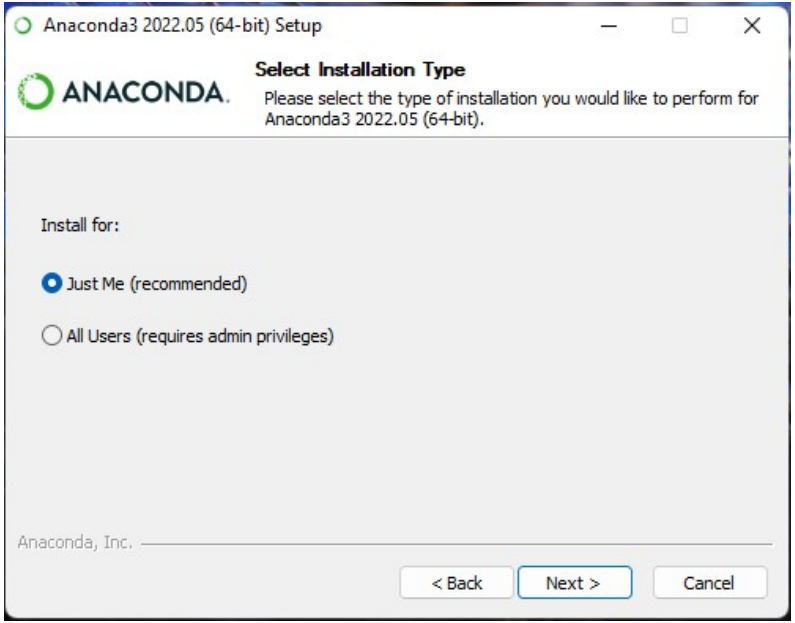


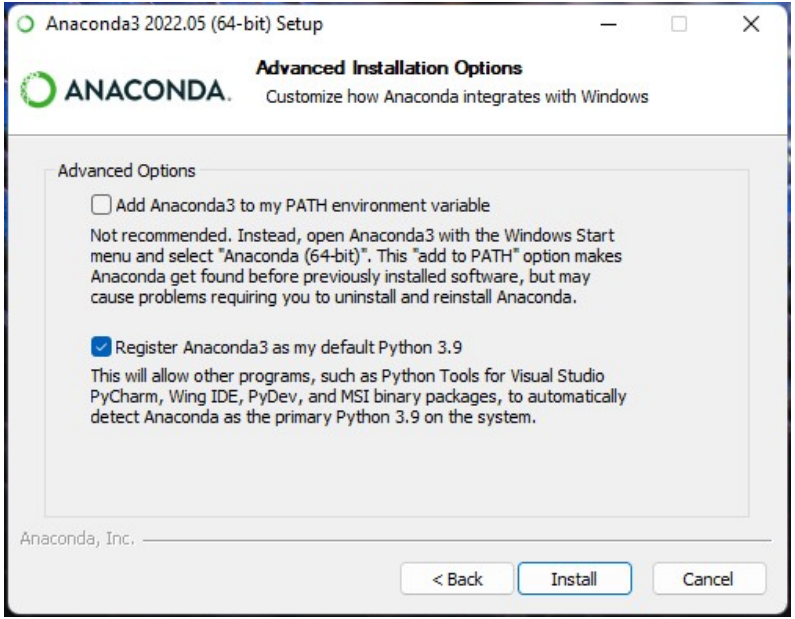


Preparar tu entorno para trabajar en ciencia de datos.

- ¿En dónde empiezo a hacer magia?
- ¿Por qué utilizar Notebooks?
- Entornos en la nube.
- Google Colab
- Kaggle Code
- Deepnote ❤️
- Entorno locales.
- WSL y Anaconda
- Windows y Anaconda
- Visual Studio Code
- Explorando Anaconda
- Entornos virtuales en Anaconda




Anaconda3 2022.05 (64-bit) Setup
ANACONDA.
Select Installation Type
Please select the type of installation you would like to perform for Anaconda3 2022.05 (64-bit).
Install for:
Just Me (recommended)
All Users (requires admin privileges)
Anaconda, Inc.
< Back
Next >
Cancel


Anaconda3 2022.05 (64-bit) Setup
ANACONDA.
Advanced Installation Options
Customize how Anaconda integrates with Windows
Advanced Options
Add Anaconda3 to my PATH environment variable
Not recommended. Instead, open Anaconda3 with the Windows Start menu and select "Anaconda (64-bit)". This "add to PATH" option makes Anaconda get found before previously installed software, but may cause problems requiring you to uninstall and reinstall Anaconda.
Register Anaconda3 as my default Python 3.9
This will allow other programs, such as Python Tools for Visual Studio PyCharm, Wing IDE, PyDev, and MSI binary packages, to automatically detect Anaconda as the primary Python 3.9 on the system.
Anaconda, Inc.
< Back
Install
Cancel



¿En dónde empiezo a hacer magia?

El primer paso es muy importante



No todo es código

En la actualidad Python es el lenguaje más popular para aplicar ciencia de datos, pero en **la ciencia de datos necesitamos mucho más que un archivo con código**, necesitamos hacer análisis, visualizar gráficos y todo esto lo podemos hacer gracias a los Jupyter Notebooks que son archivos especiales que contienen código y objetos más avanzados como imágenes o texto en Markdown.

Jupyter Notebooks = Archivo.ipynb



Una perspectiva general









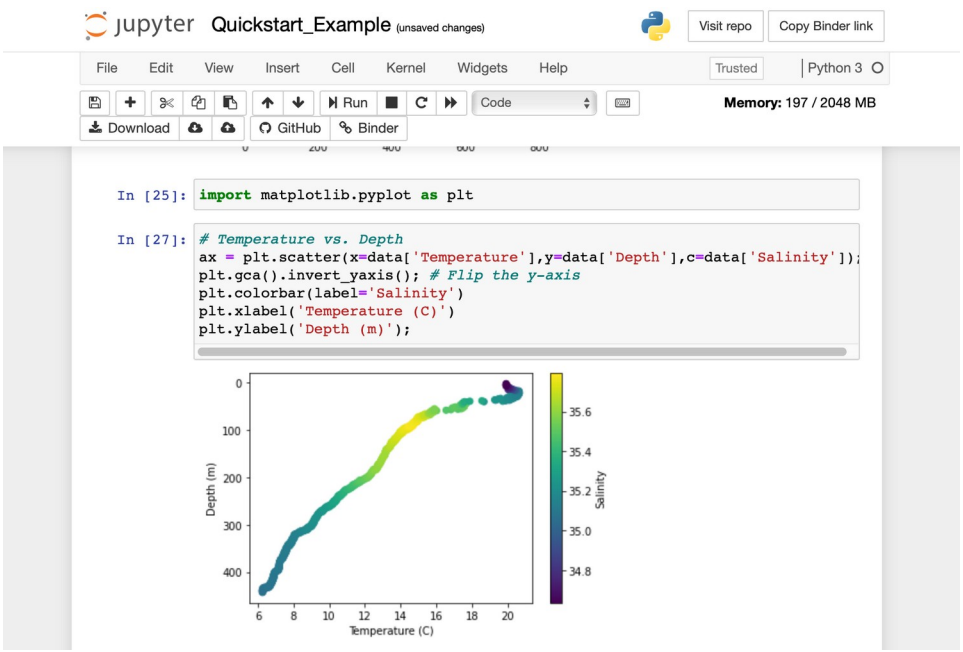








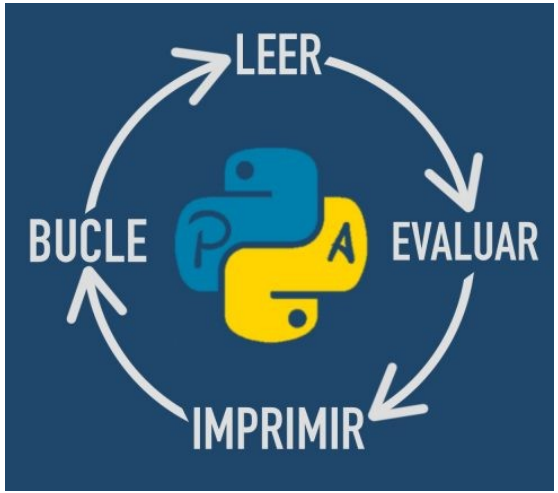




¿Por qué utilizar Notebooks?

Herramientas para ciencia de datos

Notebooks, una evolución al código



REPL (read-eval-print-loop).
Los **REPL son programas que están a la espera de que se les escriba comandos para ser ejecutados continuamente**, de ahí el nombre de lectura-evaluación-impresión-bucle.

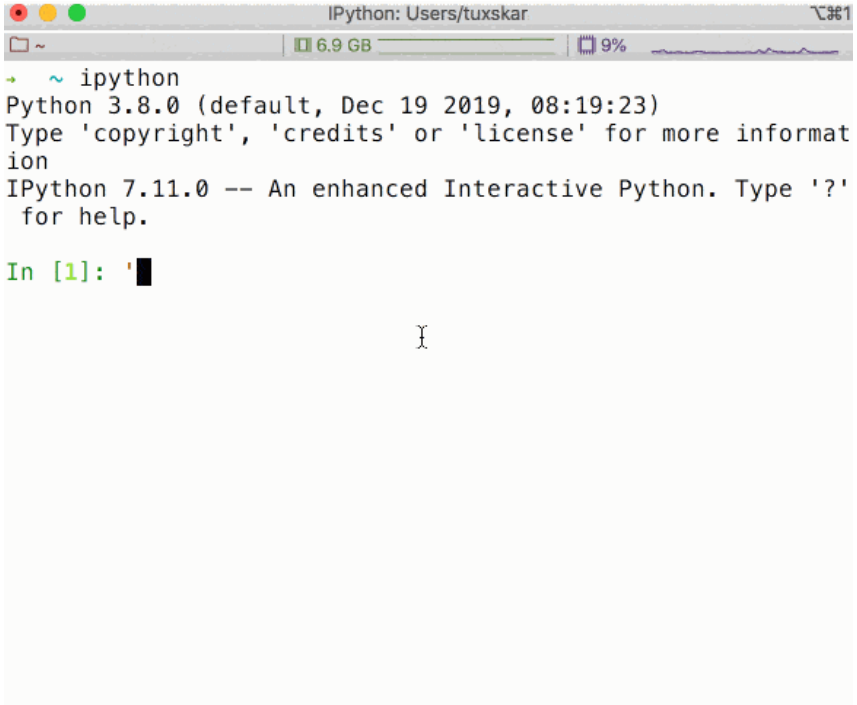
Se utilizan para lanzar sentencias Python para ser evaluadas rápidamente y es una de las herramientas más potentes que tiene el lenguaje.

Las **Notebooks** llevan todo esto al siguiente nivel teniendo una **interfaz gráfica y características extras para facilitar el análisis**.

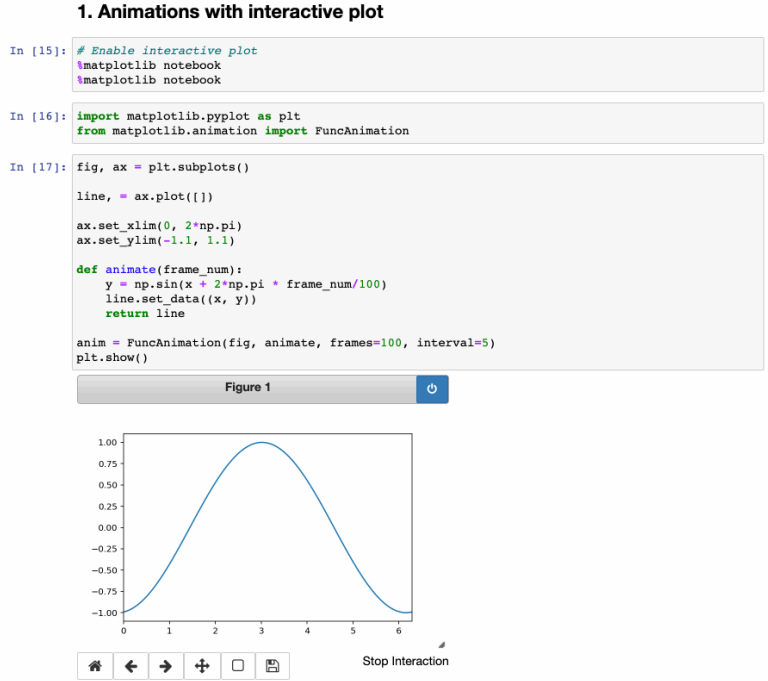


Notebooks, una evolución al código

REPL (IPython)



Jupyter Notebook



Herramientas para ciencia de datos

Código para la ciencia



Los Jupyter Notebooks son una aplicación web, que nos va a permitir **crear y compartir documentos con código, ecuaciones, visualizaciones y texto explicativo**. Estos documentos registran todo el proceso de desarrollo y análisis de ciencia de datos.

Como curiosidad, se les “bautizó” con el nombre de **Jupyter**, por las connotaciones científicas que conlleva la alusión al planeta “Júpiter”, cuyas lunas fueron protagonistas de lo que se considera una de las primeras publicaciones científicas sustentadas por datos

¿Qué podemos hacer en un Notebook?

Ejemplo Práctico



¿Dónde podemos utilizar las Notebooks?



Cloud



Local



Desarrollando ciencia de datos en entornos cloud


Google
colab

¿Que es Google colab?

Open Google Colab

Google Colab es la implementación de Notebooks en **servidores proporcionados por Google de manera gratuita** o de paga, y esto depende del uso que necesites darles, ya que incluso **podríamos personalizar estos servidores o contratar GPU** superpotentes para entrenar algoritmos de Machine Learning o Deep Learning.

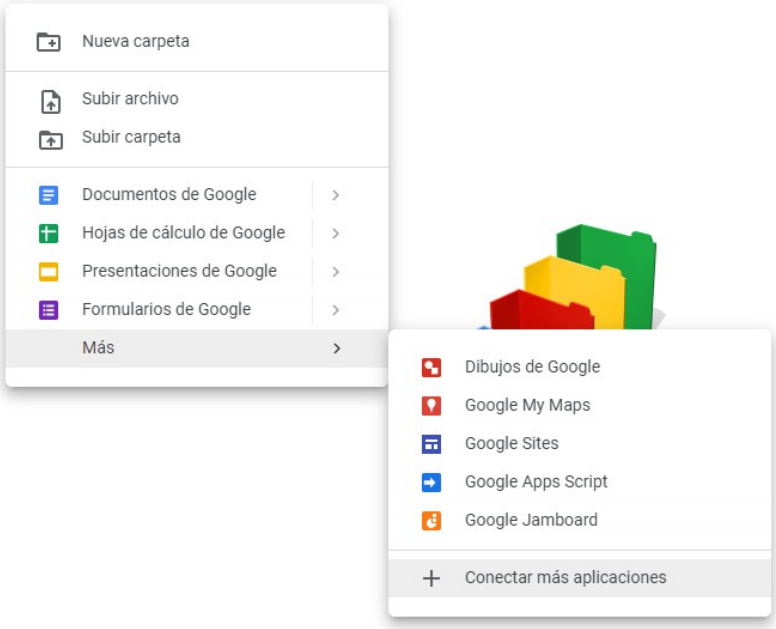
En **Google colab vamos a poder tener proyectos basados en el propio archivo**, esto quiere decir que aunque podemos tener varios Google colab, estos por defecto no tienen ninguna conexión y se utilizan como notebooks independientes, esto es importante tenerlo en cuenta porque muchas veces vamos a querer tener separadas algunas partes de nuestros proyectos.

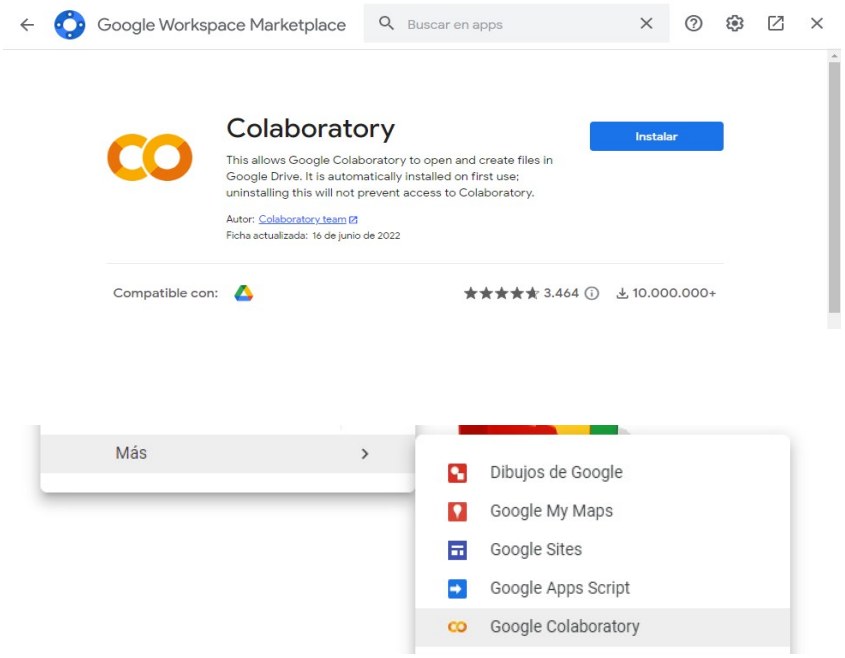
Estos ambientes creados por Google colab ya cuenta con las principales librerías utilizadas en Python para ciencia de datos.



¿Añadir Colab a nuestro Drive?

Open Google Drive






kaggle

¿Qué es Kaggle?

Open Kaggle

Kaggle es **la comunidad de ciencia de datos por excelencia y de los entusiastas del aprendizaje automático** que ofrece una variedad de recursos, competiciones y conjuntos de datos para la comunidad. **Kaggle Notebooks** es una plataforma dentro de Kaggle que te **permite crear, compartir y ejecutar cuadernos interactivos en línea**. Esta herramienta es especialmente valiosa para la comunidad de ciencia de datos, ya que combina un entorno de desarrollo colaborativo con acceso directo a los conjuntos de datos de Kaggle.

Participar en competiciones de Kaggle te brinda la oportunidad de aplicar tus habilidades en proyectos del mundo real y aprender de los enfoques de otros profesionales.





Deepnote ❤️

Herramientas para ciencia de datos



¿Qué es Deepnote?

Deepnote es la forma en que podemos llevar **nuestro entorno de trabajo completo a la nube,** ya que se trabaja a nivel de proyectos.
Es una plataforma tan robusta y con tantas posibilidades, que solo enlistaré las que más utilizo y veremos algunas extra directamente en su web.

- Embed Deepnote blocks en Notion pages para tomar notas
- GitHub
- Gráficos sin código
- Colaboración en tiempo real
- Publicación de Proyectos

Open Deepnote **Deepnote Documentation**





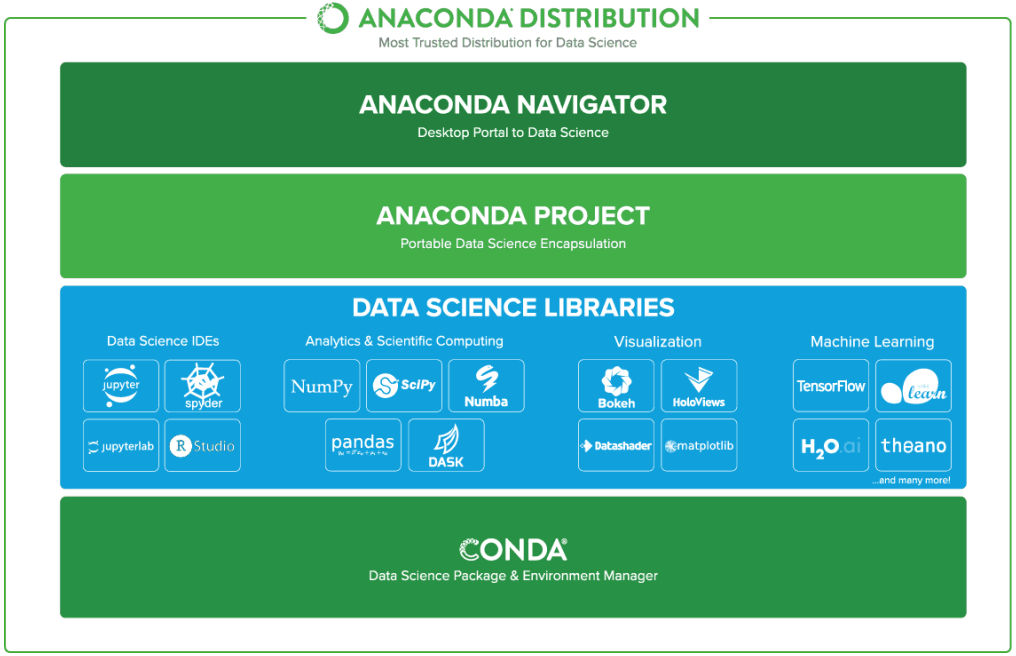
Desarrollando ciencia de datos en entornos locales

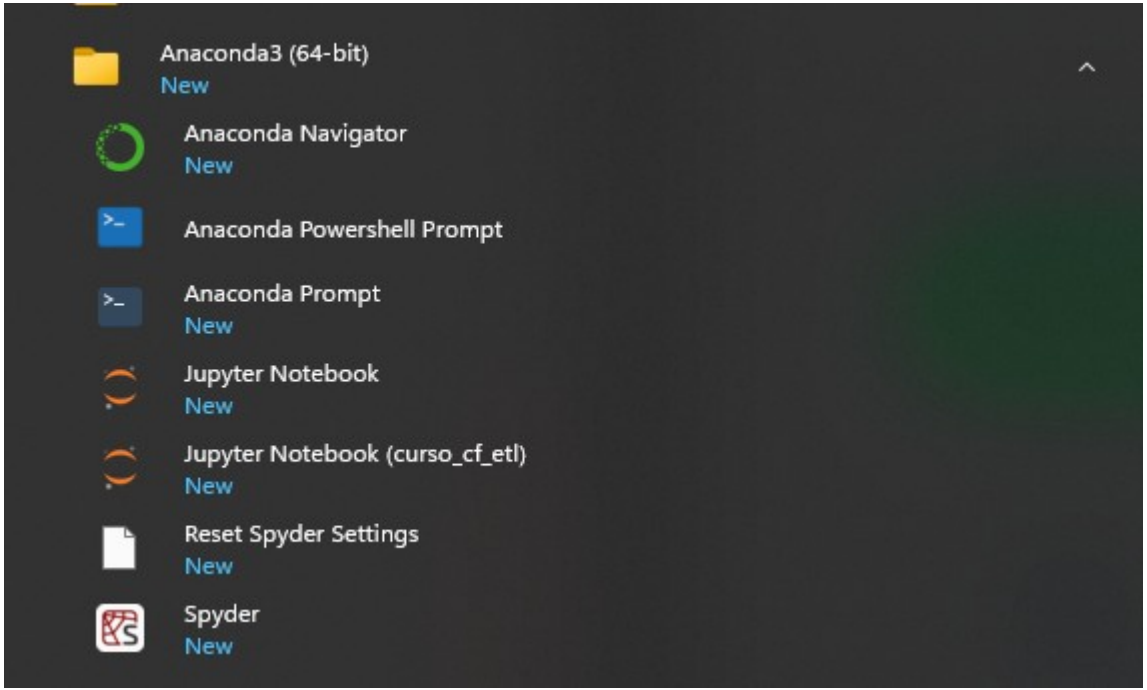

ANACONDA.

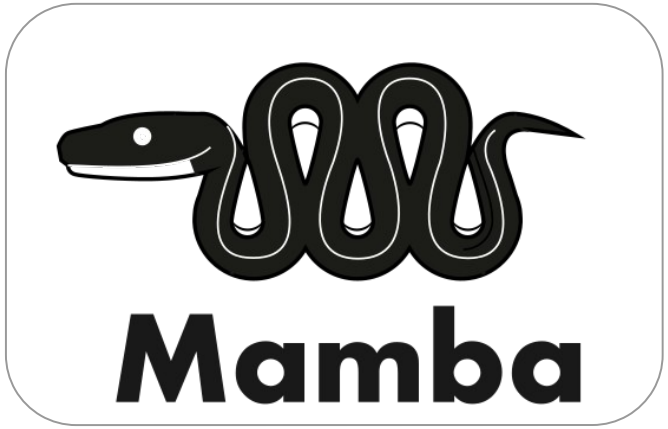
¿Qué es Anaconda?

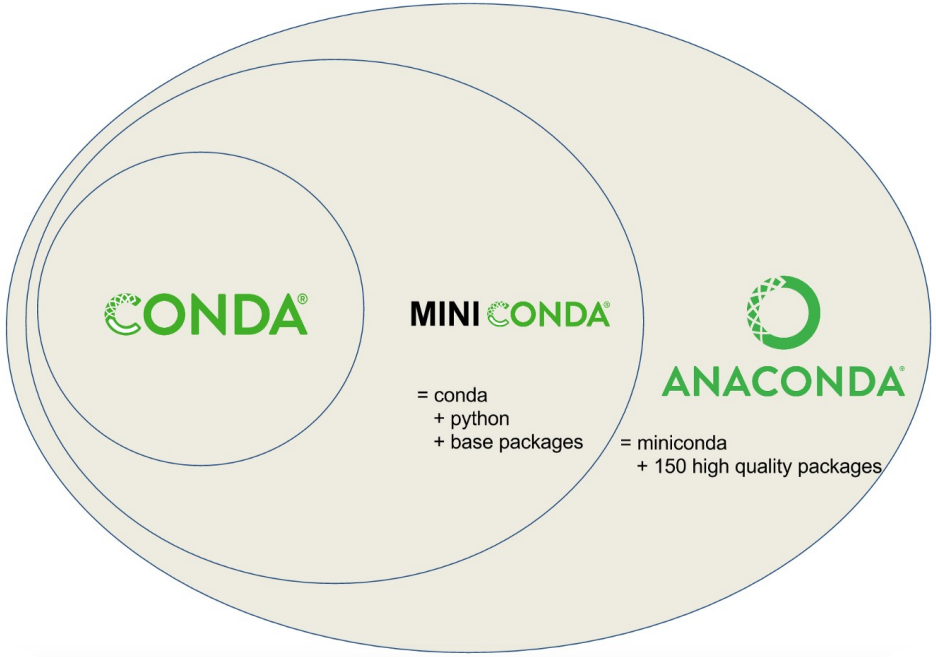
Anaconda es una distribución de los **lenguajes de programación Python y R** para computación científica (ciencia de datos, aplicaciones de Machine Learning, procesamiento de datos a gran escala, análisis predictivo, etc.).

Tiene como ventaja simplificar la gestión e implementación de paquetes. La distribución incluye paquetes de “data science” adecuados para Windows, Linux y macOS.




Anaconda3 (64-bit)
New
Anaconda Navigator
New
Anaconda Powershell Prompt
Anaconda Prompt
New
Jupyter Notebook
New
Jupyter Notebook (curso_cf_etl)
New
Reset Spyder Settings
New
Spyder
New


Mamba


CONDA
MINI CONDA
= conda
+ python
+ base packages
ANACONDA
= miniconda
+ 150 high quality packages

WSL

Combina lo mejor de los 2 mundos.

-Linux es un excelente entorno de desarrollo.
- Windows tiene toda la versatilidad de instalar aplicaciones como tableau, power bi y excel que son herramientas que utilizaremos en el día a día.



Instalación

wsl --install

Instalación en Linux o WSL

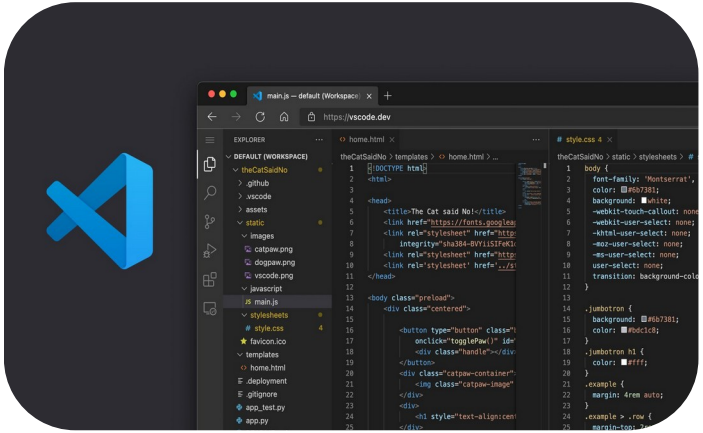
Instalación

- cd /tmp
- curl https://repo.anaconda.com/archive/Anaconda3-2022.05-Linux-x86_64.sh --output anaconda.sh
- bash anaconda.sh
- conda config --set auto_activate_base false



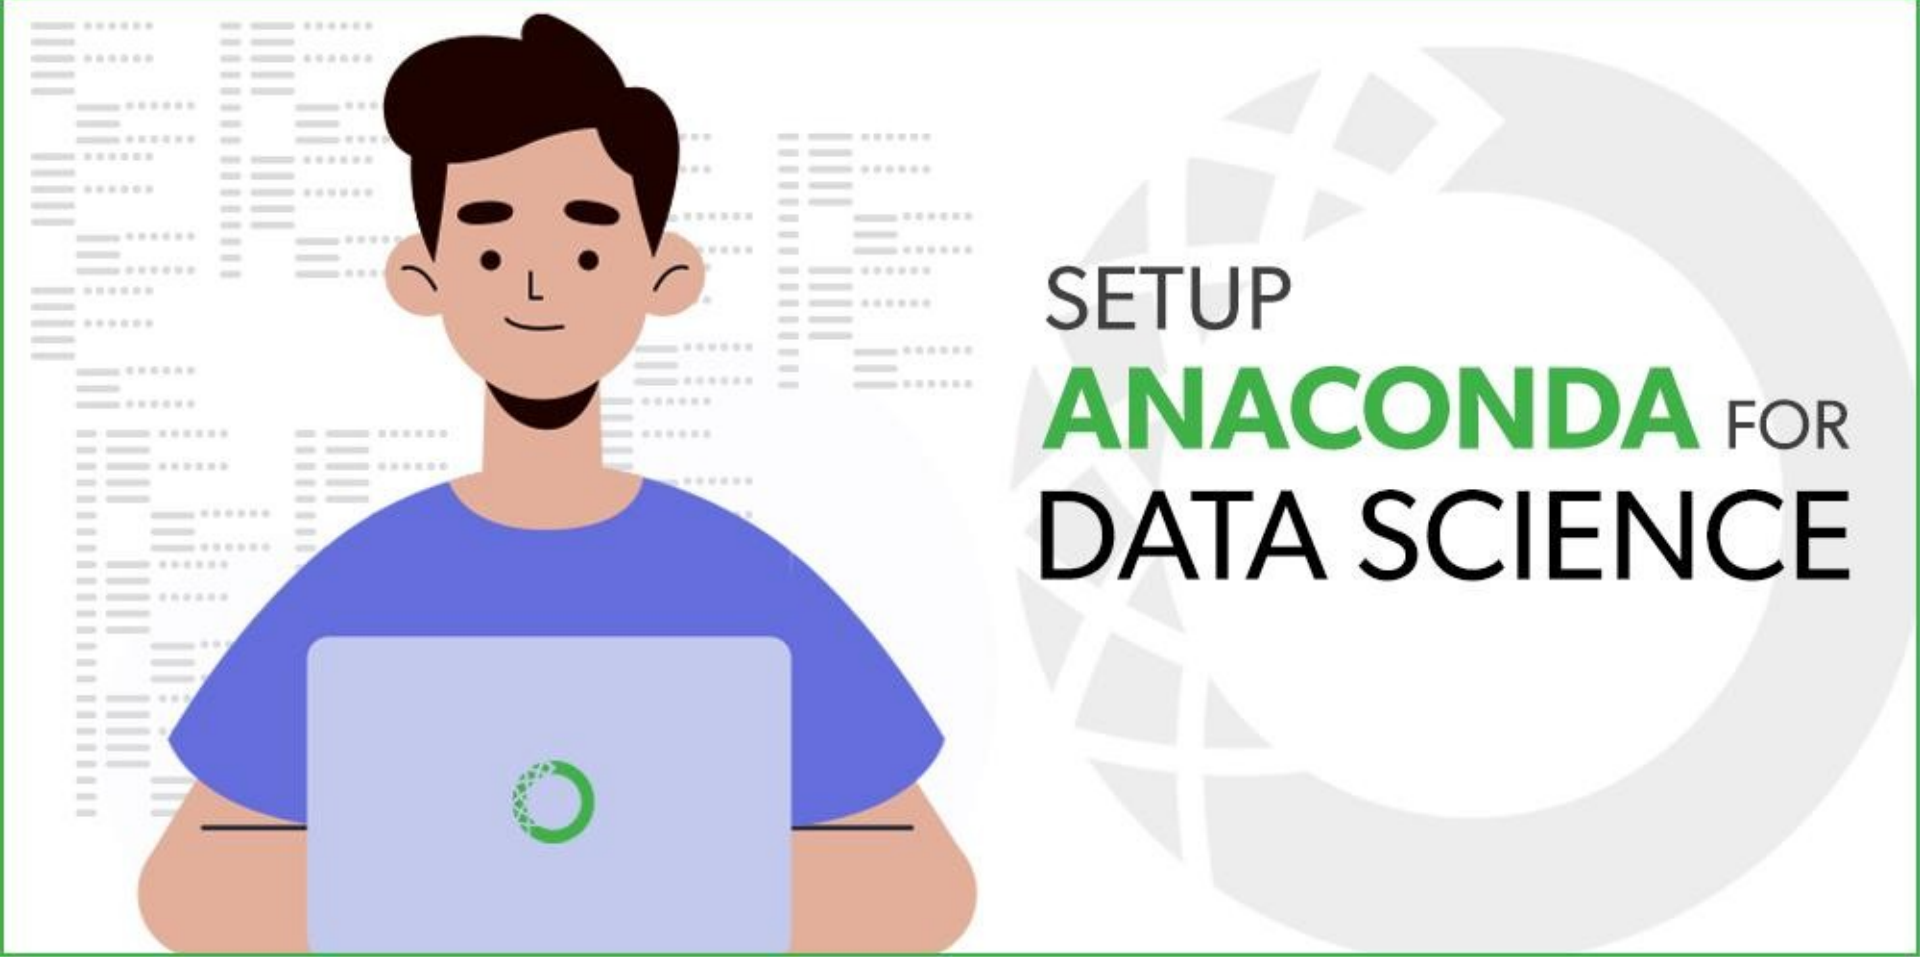
VS Code

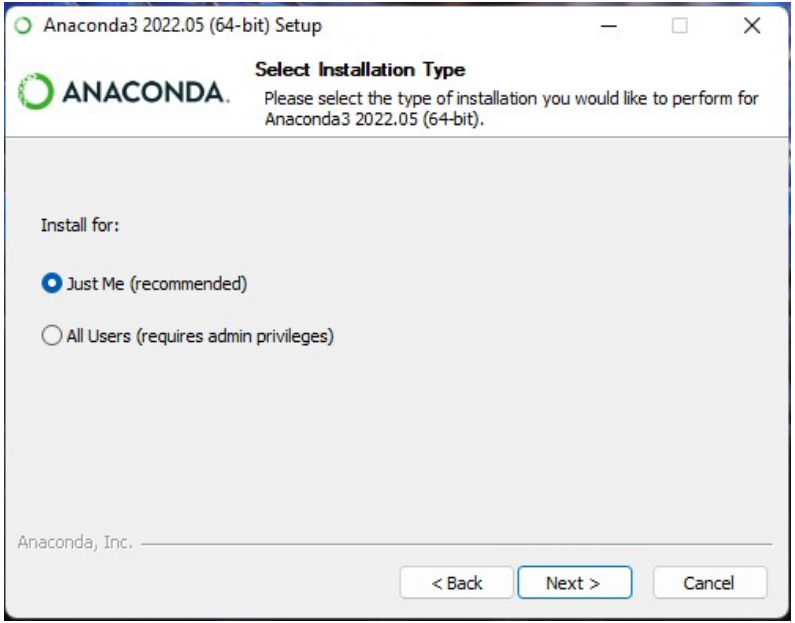
El editor de código más popular y tiene soporte para archivos ipynb y muchas más extensiones que harán que tu desarrollo sea más sencillo.

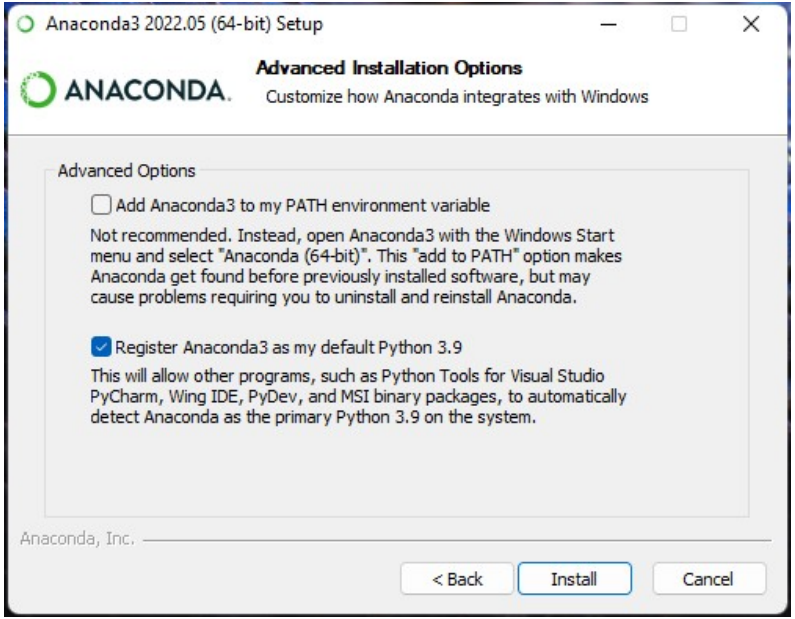


Extensiones

- Remote - WSL
- Data Science Extensions


SETUP
ANACONDA FOR
DATA SCIENCE

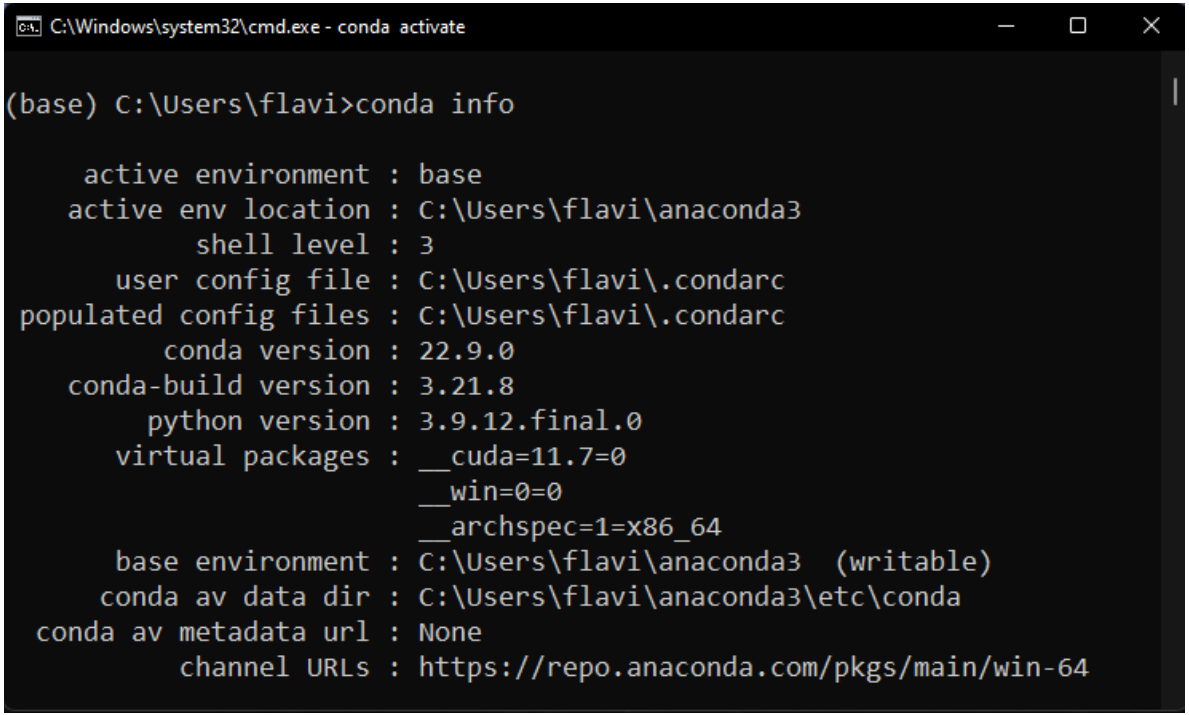

Anaconda3 2022.05 (64-bit) Setup
ANACONDA.
Select Installation Type
Please select the type of installation you would like to perform for Anaconda3 2022.05 (64-bit).
Install for:
Just Me (recommended)
All Users (requires admin privileges)
Anaconda, Inc.
< Back
Next >
Cancel


Anaconda3 2022.05 (64-bit) Setup
ANACONDA.
Advanced Installation Options
Customize how Anaconda integrates with Windows
Advanced Options
Add Anaconda3 to my PATH environment variable
Not recommended. Instead, open Anaconda3 with the Windows Start menu and select "Anaconda (64-bit)". This "add to PATH" option makes Anaconda get found before previously installed software, but may cause problems requiring you to uninstall and reinstall Anaconda.
Register Anaconda3 as my default Python 3.9
This will allow other programs, such as Python Tools for Visual Studio PyCharm, Wing IDE, PyDev, and MSI binary packages, to automatically detect Anaconda as the primary Python 3.9 on the system.
Anaconda, Inc.
< Back
Install
Cancel



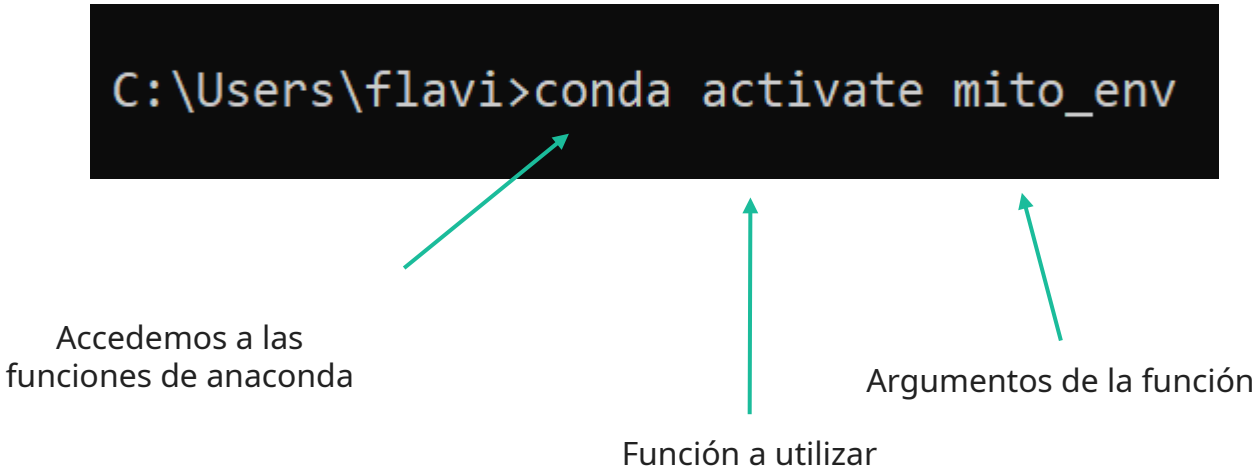
Herramientas para ciencia de datos

Entornos virtuales en Anaconda



Entornos virtuales en Anaconda

Estructura de comandos en Anaconda



Comandos más utilizados en Anaconda

Creación de env

```
(base) C:\Users\flavi>conda create --name mito python pandas jupyter
```

Accedemos a las funciones de anaconda

Función para crear env

Nombre del env

Librerías a instalar

```
(base) C:\Users\flavi>conda create --name <env> --file requirements.txt
```

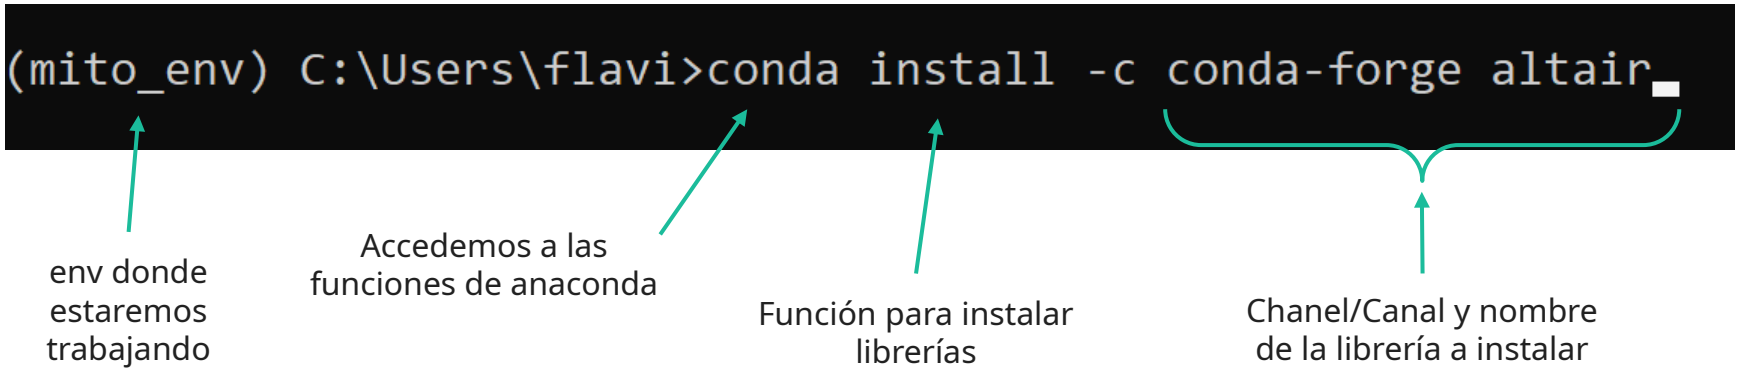



Comandos más utilizados en Anaconda

Alternativa pip

```
(mito_env) C:\Users\flavi>pip install altair vega_datasets
```

Instalación de Librerías



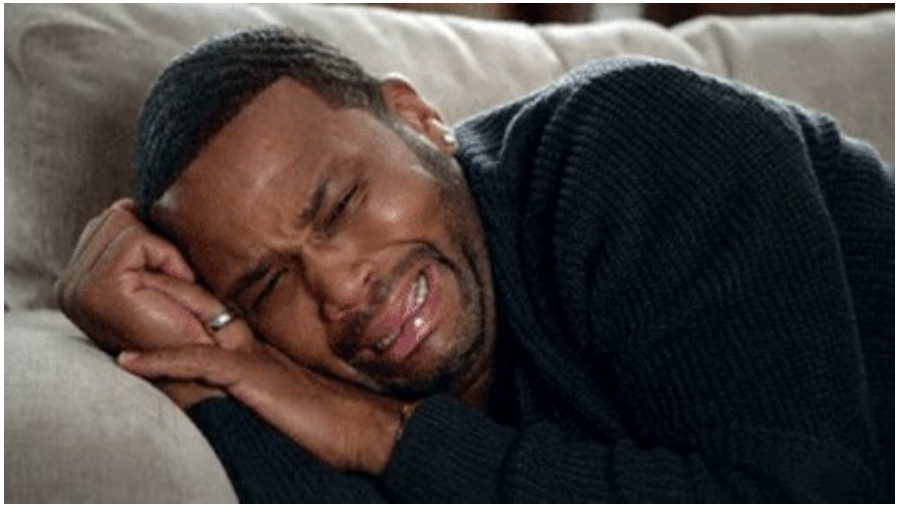
Open conda packages

Se rompió tu env al instalar una nueva librería o actualizar
Anaconda tiene una función para estos casos

Anaconda Revisions

Es la manera en como anaconda versiona los cambios realizados en tu entorno

- *conda list –revisions*
- *conda install –revisions <No. Rev>*



Comandos más utilizados en Anaconda

Exportar env con las librerías utilizadas

```
(mito_env) C:\Users\flavi>conda list -e > requirements.txt
```

Accedemos a las funciones de anaconda

Función para listar las librerías del env

enviamos el resultado al archivo requirements.txt



Comandos más utilizados en Anaconda

Exportar env con las librerías especificadas por el usuario

```
(mito_env) C:\Users\flavi>conda env export --from-history
name: mito_env
channels:
  - defaults
dependencies:
  - jupyter
  - pandas
  - python
prefix: C:\Users\flavi\anaconda3\envs\mito_env

(mito_env) C:\Users\flavi>conda env export --from-history --file enviroment_mito_env.yml

(mito_env) C:\Users\flavi>conda create --file enviroment_mito_env.yml
```




Notebooks con env de Anaconda

```
(base) C:\Users\flavi\OneDrive\Documentos\Curso codigofacilito>code .

(base) C:\Users\flavi\OneDrive\Documentos\Curso codigofacilito>jupyter-notebook
```




¿Dudas?



Gracias

